TFM

Alumna: María Carolina Passarello.

Anexo Gastronomía.

Para este experimento se utilizó el MANUAL & RECETARIO para la Carrera de PROFESIONAL GASTRONÓMICO II

url del manual:

https://www.azafran.com.ar/Azafran 2019/COCINA II MANUAL Y RECETARIO PG II 2019.pdf

o también en https://docer.ar/doc/ex1v

Objetivo del Documento

El objetivo del "Manual y Recetario de Cocina II" es proporcionar a los estudiantes y profesionales de la gastronomía una guía completa sobre la preparación de diversas recetas y técnicas culinarias, abarcando diferentes cocinas del mundo. Incluye desde generalidades de la gastronomía de varios países, pasando por técnicas y preparaciones específicas, hasta recetas detalladas.

Resumen del Contenido

El recetario está dividido en varias secciones, cada una dedicada a la gastronomía de un país específico. Cada sección incluye una introducción general sobre la cocina del país, técnicas y preparaciones comunes, y una colección de recetas tradicionales. Algunos de los países cubiertos son:

- 1. **Francia**: Se destaca por su refinada gastronomía, con recetas como la fondue, quiches, crêpes, y soufflés.
- 2. **España**: Incluye platos como la paella, migas, pulpo a la gallega y diversas tapas.
- 3. Italia: Presenta recetas como el calzone, risotto, pasta, y diversas ensaladas.
- 4. **México**: Se enfoca en platos con influencias prehispánicas y coloniales como el guacamole, cochinita pibil y chiles rellenos.
- 5. **Perú**: Incluye recetas emblemáticas como el ceviche, causa limeña y anticuchos.
- 6. **India**: Presenta una variedad de currys, chutneys, y panes tradicionales como los chapatis.
- 7. **Argentina**: Destaca por sus carnes, con recetas como el locro, empanadas y asados.
- 8. **Cocina Oriental**: Abarca diversas recetas de la cocina asiática como sushi, tempura y rolls.

Cada receta incluye los ingredientes necesarios, el procedimiento de preparación, y consejos para su correcta elaboración. Además, se proporcionan técnicas culinarias esenciales para la preparación de estos platos.

El documento " Manual y Recetario de Cocina II " tiene las siguientes estadísticas:

• Número de páginas: 205

• Número total de palabras: 38,550

TFM

Alumna: María Carolina Passarello.

• **Número de secciones identificadas:** 0 (esto se debe a que los títulos de las secciones no coinciden exactamente con las palabras clave predefinidas)

Explicación de las Métricas. Se realiza una explicación de las métricas utilizadas para analizar cada respuesta obtenida mediante la generación en cada implementación.

<u>Implementaciones.</u> Se especifican las implementaciones y se indica el archivo con su respectivo código fuente.

Experimento.

Se realiza una aclaración respecto a la estructura de las preguntas y respuestas.

Se detallan de manera enumerada las preguntas realizadas en la plataforma de LE CHAT MISTRAL y sus correspondientes respuestas.

Luego se detalla la respuesta esperada y la respuesta generada, así como las métricas obtenidas y el análisis de las mismas para cada implementación.

Explicación de las Métricas

ROUGE (Recall-Oriented Understudy for Gisting Evaluation)

Las métricas ROUGE miden la superposición de n-gramas entre la respuesta generada y la respuesta de referencia (esperada). Se utilizan comúnmente para evaluar la calidad de resúmenes y textos generados.

1. **ROUGE-1**:

- **Precision**: Mide la proporción de unigramas (palabras individuales) en la respuesta generada que también están en la respuesta de referencia.
- **Recall**: Mide la proporción de unigramas en la respuesta de referencia que también están en la respuesta generada.
- **F1-score**: Es la media armónica entre la precisión y el recall, proporcionando una medida balanceada de ambos.

2. **ROUGE-2**:

- **Precision:** Mide la proporción de bigramas (pares de palabras consecutivas) en la respuesta generada que también están en la respuesta de referencia.
- **Recall:** Mide la proporción de bigramas en la respuesta de referencia que también están en la respuesta generada.
- **F1-score:** Es la media armónica entre la precisión y el recall para bigramas.

3. **ROUGE-L**:

- **Precision:** Mide la proporción de la subsecuencia más larga común (LCS) en la respuesta generada que también está en la respuesta de referencia.
- **Recall:** Mide la proporción de la LCS en la respuesta de referencia que también está en la respuesta generada.
- **F1-score:** Es la media armónica entre la precisión y el recall para la LCS.

BERTScore

TFM

Alumna: María Carolina Passarello.

BERTScore es una métrica basada en embeddings que utiliza modelos de lenguaje preentrenados como BERT para evaluar la similitud semántica entre la respuesta generada y la respuesta de referencia.

- **Precision:** Mide la proporción de tokens en la respuesta generada que tienen una alta similitud con los tokens en la respuesta de referencia.
- **Recall:** Mide la proporción de tokens en la respuesta de referencia que tienen una alta similitud con los tokens en la respuesta generada.
- **F1:** Es la media armónica entre la precisión y el recall, proporcionando una medida balanceada de ambos.

Implementaciones.

Todas las implementaciones se realizaron en Python sobre Google Colab.

Preguntas y respuestas generadas con:

• Implementación 1: RAG Básico.

Todos los detalles de esta implementación pueden analizarse en el archivo

RagBasicoconPymuPDFGastronomia.ipynb

Implementación 2: RAG con Haystack

Todos los detalles de esta implementación pueden analizarse en el archivo

RagConHaystackconPymuPDFGastronomia.ipynb

• Implementación 3: RAG con LlamaIndex

Todos los detalles de esta implementación pueden analizarse en el archivo

RAGconLlamaIndexconPymuPDFGastronomia.ipynb

• GastronomicoMetricasLeChat.ipynb

Se implementa el cálculo de las métricas de las respuestas generadas por LECHAT, es decir, son las métricas SIN RAG.

Experimento.

Observación: estructura de las preguntas y respuestas con la plataforma de LE CHAT MISTRAL.

Se realizaron las mismas preguntas a la plataforma LE CHAT con las que se evaluaron con el sistema RAG en sus tres implementaciones. En cada respuesta se puede apreciar la generalización en la respuesta debido a que el LLM no posee información exacta del contexto en cuestión (Guías INSARAG Volumen II - Manual B) pero si posee información general acerca de esta guía.

En este experimento se detallan las preguntas y capturas de pantalla de las respuestas obtenidas por la plataforma LECHAT. Luego las respuestas generadas en cada implementación. Aclaración: la respuesta esperada en cada implementación es la

TFM

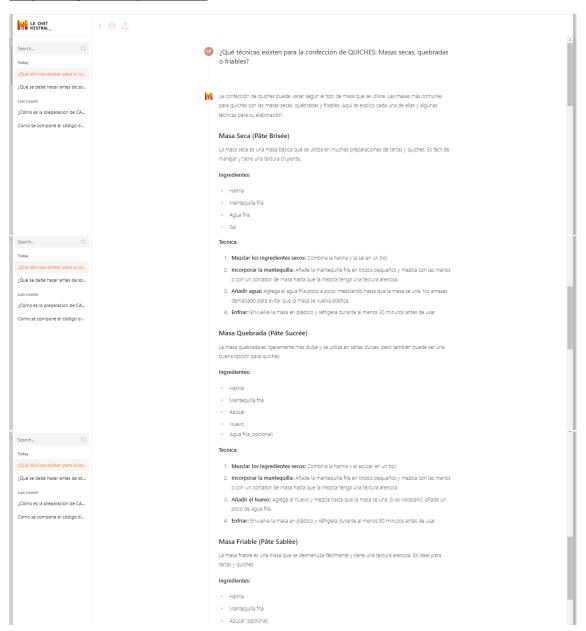
Alumna: María Carolina Passarello.

misma para poder realizar una comparación exacta de esta con cada respuesta generada obteniendo de estas las respectivas métricas. Luego por cada respuesta se detallan los valores obtenidas de las métricas utilizadas para evaluar las respuestas obtenidas.

Preguntas y respuestas del experimento.

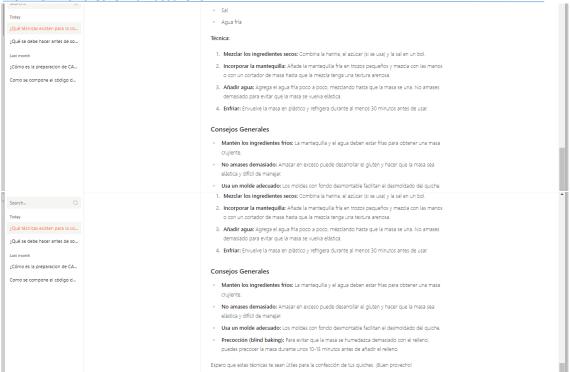
Pregunta 1: ¿Qué técnicas existen para la confección de QUICHES: Masas secas, quebradas o friables?

Respuesta generada por LECHAT



TFM

Alumna: María Carolina Passarello.



Transcripción.

La confección de quiches puede variar según el tipo de masa que se utilice. Las masas más comunes para quiches son las masas secas, quebradas y friables. Aquí te explico cada una de ellas y algunas técnicas para su elaboración:

Masa Seca (Pâte Brisée)

La masa seca es una masa básica que se utiliza en muchas preparaciones de tartas y quiches. Es fácil de manejar y tiene una textura crujiente.

Ingredientes:

- Harina
- Mantequilla fría
- Agua fría
- Sal

Técnica:

- 1. **Mezclar los ingredientes secos:** Combina la harina y la sal en un bol.
- 2. **Incorporar la mantequilla:** Añade la mantequilla fría en trozos pequeños y mezcla con las manos o con un cortador de masa hasta que la mezcla tenga una textura arenosa.
- 3. **Añadir agua:** Agrega el agua fría poco a poco, mezclando hasta que la masa se una. No amases demasiado para evitar que la masa se vuelva elástica.

TFM

Alumna: María Carolina Passarello.

4. **Enfriar:** Envuelve la masa en plástico y refrigera durante al menos 30 minutos antes de usar.

Masa Quebrada (Pâte Sucrée)

La masa quebrada es ligeramente más dulce y se utiliza en tartas dulces, pero también puede ser una buena opción para quiches.

Ingredientes:

- Harina
- Mantequilla fría
- Azúcar
- Huevo
- Agua fría (opcional)

Técnica:

- 1. **Mezclar los ingredientes secos:** Combina la harina y el azúcar en un bol.
- 2. **Incorporar la mantequilla:** Añade la mantequilla fría en trozos pequeños y mezcla con las manos o con un cortador de masa hasta que la mezcla tenga una textura arenosa.
- 3. **Añadir el huevo:** Agrega el huevo y mezcla hasta que la masa se una. Si es necesario, añade un poco de agua fría.
- 4. **Enfriar:** Envuelve la masa en plástico y refrigera durante al menos 30 minutos antes de usar.

Masa Friable (Pâte Sablée)

La masa friable es una masa que se desmenuza fácilmente y tiene una textura arenosa. Es ideal para tartas y quiches.

Ingredientes:

- Harina
- Mantequilla fría
- Azúcar (opcional)
- Sal
- Agua fría

Técnica:

- 1. **Mezclar los ingredientes secos:** Combina la harina, el azúcar (si se usa) y la sal en un bol.
- 2. **Incorporar la mantequilla:** Añade la mantequilla fría en trozos pequeños y mezcla con las manos o con un cortador de masa hasta que la mezcla tenga una textura arenosa.

TFM

Alumna: María Carolina Passarello.

- 3. **Añadir agua:** Agrega el agua fría poco a poco, mezclando hasta que la masa se una. No amases demasiado para evitar que la masa se vuelva elástica.
- 4. **Enfriar:** Envuelve la masa en plástico y refrigera durante al menos 30 minutos antes de usar.

Consejos Generales

- Mantén los ingredientes fríos: La mantequilla y el agua deben estar frías para obtener una masa crujiente.
- No amases demasiado: Amasar en exceso puede desarrollar el gluten y hacer que la masa sea elástica y difícil de manejar.
- Usa un molde adecuado: Los moldes con fondo desmontable facilitan el desmoldado del quiche.
- Precocción (blind baking): Para evitar que la masa se humedezca demasiado con el relleno, puedes precocer la masa durante unos 10-15 minutos antes de añadir el relleno.

Espero que estas técnicas te sean útiles para la confección de tus quiches. ¡Buen provecho!

Métricas sin RAG.

Análisis de las métricas.

1. ROUGE-1 Score:

- **Precision**: 0.085 indica que solo el 8.5% de las palabras recuperadas coinciden con las palabras relevantes en el texto de referencia.
- **Recall**: 0.644 significa que el 64.5% de las palabras relevantes del texto de referencia fueron capturadas por el sistema.
- F1-Score: 0.150 indica un balance entre precisión y recall, sugiriendo que aunque el sistema es capaz de capturar muchas palabras relevantes, su precisión es baja.

2. ROUGE-2 Score:

- Precision: 0.031 señala que solo el 3.1% de las secuencias de dos palabras ("bigrams") son correctas en comparación con el texto de referencia.
- **Recall**: 0.24 indica que el sistema recupera el 24% de los bigrams relevantes.
- o **F1-Score**: 0.055 refleja una correspondencia moderadamente baja entre los bigrams del texto generado y el de referencia.

3. ROUGE-L Score:

- Precision: 0.056 muestra que solo el 5.6% de las coincidencias están en la secuencia más larga de coincidencias entre la respuesta generada y el texto de referencia.
- **Recall**: 0.421 significa que el sistema captura el 42.1% de la secuencia más larga de coincidencias relevantes.
- **F1-Score**: 0.098 sugiere que la capacidad del sistema para seguir la estructura del texto de referencia en secuencias largas es baja.

4. **BERTScore**:

- o **Precision**: 0.624 muestra que el 62.4% de las palabras generadas son semánticamente relevantes según el modelo BERT.
- **Recall**: 0.692 indica que el sistema captura el 69.2% del contenido semántico importante.
- F1-Score: 0.656 es un buen indicador de que las respuestas generadas están alineadas semánticamente con el texto de referencia, superando las métricas ROUGE.

Conclusión: Las métricas ROUGE muestran que el sistema tiene un buen recall (recupera muchas palabras relevantes), pero la precisión es baja, lo que indica que el texto generado incluye mucho contenido irrelevante. El BERTScore, que mide la similitud semántica, ofrece una evaluación más favorable, lo que sugiere que aunque la correspondencia literal entre las palabras es baja, el sistema es razonablemente bueno capturando el significado general de las respuestas.

Respuesta esperada (en las tres implementaciones es la misma respuesta):

Existen dos técnicas para su confección:

• Sableado: haciendo "grumos" con harina y manteca fría y luego tomar la masa con los

líquidos.

• Emulsión: comenzando por batir manteca, azúcar y líquidos hasta emulsionar y luego

incorporar la harina.

Todas las masas pueden hacerse por cualquiera de las técnicas, pero se aconseja el sableado para

la brisée y la emulsión para sablée, frôla y sucrée.

Respuesta generada con RAG Básico:

Existen dos técnicas para la confección de QUICHES: Masas secas, quebradas o friables:

- 1. **Sableado**: Esta técnica consiste en hacer "grumos" con harina y manteca fría y luego tomar la masa con los líquidos.
- 2. **Emulsión**: Esta técnica comienza por batir manteca, azúcar y líquidos hasta emulsionar y luego incorporar la harina.

TFM

Alumna: María Carolina Passarello.

Se aconseja el sableado para la masa brisée y la emulsión para las masas sablée, frôla y sucrée.

Métricas:

```
ROUGE-1 score: Score(precision=0.7857142857142857, recall=0.868421052631579, fmeasure=0.825)
ROUGE-2 score: Score(precision=0.6506024096385542, recall=0.72, fmeasure=0.6835443037974683)
ROUGE-L score: Score(precision=0.7261904761904762, recall=0.8026315789473685, fmeasure=0.7625)
BERTScore - Precision: 0.8199255466461182, Recall: 0.8542822599411011, F1: 0.836751401424408
```

Análisis de las Métricas

1. ROUGE-1 Score:

- Precision: 0.786 indica que el 78.6% de las palabras generadas por el sistema son relevantes en comparación con las del texto de referencia.
- **Recall**: 0.868 sugiere que el sistema captura el 86.8% de las palabras relevantes.
- o **F1-Score**: 0.825 es un valor alto, lo que significa que el sistema tiene un buen balance entre precisión y recall, mostrando que genera palabras relevantes de manera efectiva.

2. ROUGE-2 Score:

- **Precision**: 0.651 muestra que el 65.1% de los bigrams generados son correctos en comparación con el texto de referencia.
- **Recall**: 0.72 indica que el 72% de los bigrams relevantes fueron recuperados por el sistema.
- **F1-Score**: 0.684 es un buen balance entre precisión y recall para las secuencias de dos palabras, indicando que el sistema captura secuencias de palabras significativas.

3. **ROUGE-L Score**:

- Precision: 0.726 significa que el 72.6% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias entre el texto generado y el texto de referencia.
- **Recall**: 0.803 indica que el sistema recupera el 80.3% de la secuencia relevante más larga.
- o **F1-Score**: 0.763 refleja un buen equilibrio entre precisión y recall para las coincidencias más largas, lo que sugiere que el sistema mantiene la estructura del texto de referencia de manera efectiva.

4. BERTScore:

- o **Precision**: 0.820 muestra que el 82% de las palabras generadas por el sistema son semánticamente relevantes.
- **Recall**: 0.854 indica que el sistema captura el 85.4% del contenido semántico importante.
- **F1-Score**: 0.837 indica una excelente correspondencia semántica entre las respuestas generadas y el texto de referencia.

Conclusión: Estas métricas muestran un rendimiento significativamente mejor que en el análisis anterior. El sistema tiene una alta precisión y recall, tanto en términos de coincidencia literal (ROUGE) como de similitud semántica (BERTScore). Esto sugiere

TFM

Alumna: María Carolina Passarello.

que el sistema no solo captura la mayoría de las palabras y secuencias relevantes, sino que también genera respuestas alineadas con el significado del texto de referencia, siendo muy eficaz tanto a nivel sintáctico como semántico.

Respuesta generada con RAG con Haystack:

Existen dos técnicas principales para la confección de masas secas, quebradas o friables:

- 1. **Sableado**: Esta técnica consiste en hacer "grumos" con harina y manteca fría, y luego tomar la masa con los líquidos.
- 2. **Emulsión**: Esta técnica comienza por batir manteca, azúcar y líquidos hasta emulsionar, y luego incorporar la harina.

Todas las masas pueden hacerse por cualquiera de las técnicas, pero se aconseja el sableado para la brisée y la emulsión para sablée, frôla y sucrée. Es importante no amasar demasiado las masas para no darles elasticidad y es imprescindible el descanso de las masas en frío antes de su utilización.

Métricas:

Análisis de las Métricas

1. **ROUGE-1 Score**:

- o **Precision**: 0.617 indica que el 61.7% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.974 significa que el sistema captura el 97.4% de las palabras relevantes.
- F1-Score: 0.755 refleja un buen balance, mostrando que el sistema tiene una capacidad alta para generar palabras relevantes, aunque con menor precisión.

2. ROUGE-2 Score:

- o **Precision**: 0.555 sugiere que el 55.5% de los bigrams generados coinciden con los del texto de referencia.
- Recall: 0.88 indica que el sistema captura el 88% de los bigrams relevantes.
- F1-Score: 0.680 es un buen equilibrio entre precisión y recall, lo que indica que el sistema capta correctamente secuencias de palabras significativas, aunque no todas.

3. ROUGE-L Score:

- o **Precision**: 0.608 indica que el 60.8% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.961 muestra que el sistema recupera el 96.1% de la secuencia relevante más larga.
- o **F1-Score**: 0.745 refleja un buen rendimiento en la captura de la estructura del texto de referencia, aunque con menor precisión.

4. **BERTScore**:

- o **Precision**: 0.841 muestra que el 84.1% de las palabras generadas son semánticamente relevantes.
- Recall: 0.939 indica que el sistema captura el 93.9% del contenido semántico relevante.
- F1-Score: 0.887 es un valor muy alto, lo que sugiere una excelente correspondencia semántica entre las respuestas generadas y el texto de referencia.

Conclusión: Las métricas indican que el sistema tiene un recall excepcional, recuperando la mayoría de las palabras y secuencias relevantes del texto de referencia, aunque su precisión es algo menor. El **BERTScore** refleja que las respuestas generadas son altamente coherentes semánticamente con el texto de referencia, lo que es un fuerte indicador de calidad en la generación de respuestas. Aunque hay una ligera caída en precisión, el sistema es eficaz en capturar tanto el contenido literal como semántico.

Respuesta generada con RAG con LLamaIndex

Existen dos técnicas para la confección de masas secas, quebradas o friables: el sableado y la emulsión. El sableado implica hacer "grumos" con harina y manteca fría y luego tomar la masa con los líquidos. La emulsión, por otro lado, comienza por batir manteca, azúcar y líquidos hasta emulsionar y luego incorporar la harina.

Métricas

Análisis de las Métricas

1. ROUGE-1 Score:

- o **Precision**: 0.839 indica que el 83.9% de las palabras generadas son relevantes en comparación con el texto de referencia.
- o **Recall**: 0.684 significa que el sistema captura el 68.4% de las palabras relevantes.
- F1-Score: 0.754 refleja un buen equilibrio, pero muestra que el sistema es más preciso que exhaustivo (recupera menos palabras relevantes de las posibles).

2. ROUGE-2 Score:

- o **Precision**: 0.656 sugiere que el 65.6% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 0.533 indica que el sistema captura el 53.3% de los bigrams relevantes.
- F1-Score: 0.588 refleja un equilibrio moderado, pero también muestra que el sistema es más preciso que exhaustivo en la generación de bigrams.

3. **ROUGE-L Score**:

- Precision: 0.661 indica que el 66.1% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias con el texto de referencia
- o **Recall**: 0.539 significa que el sistema recupera el 53.9% de la secuencia relevante más larga.
- o **F1-Score**: 0.594 sugiere un rendimiento moderado en términos de estructurar correctamente las secuencias más largas.

4. **BERTScore**:

- **Precision**: 0.827 muestra que el 82.7% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.789 indica que el sistema captura el 78.9% del contenido semántico relevante.
- F1-Score: 0.807 muestra un buen balance entre precisión y recall, lo que indica que las respuestas generadas tienen una buena correspondencia semántica con el texto de referencia.

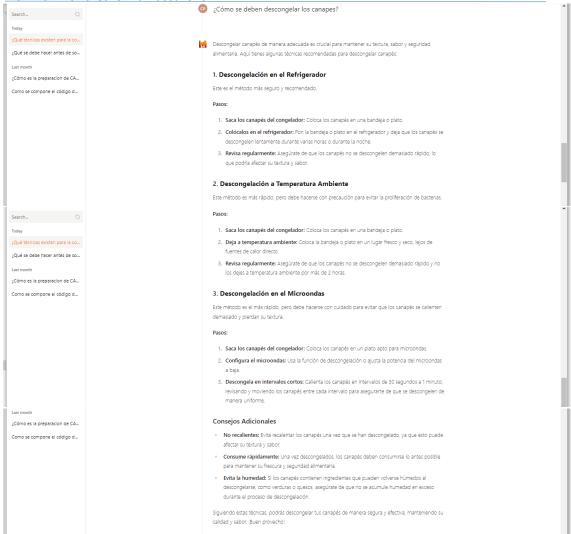
Conclusión: Las métricas muestran que el sistema es bastante preciso en términos de capturar palabras y secuencias relevantes, aunque su capacidad para recuperar todas las posibles palabras y secuencias relevantes es algo más limitada. El **BERTScore** indica que las respuestas generadas son coherentes desde el punto de vista semántico, aunque podrían beneficiarse de un mayor recall para capturar más detalles del texto de referencia. En general, el sistema tiene una buena calidad, pero puede mejorar en la recuperación completa de información relevante.

Pregunta 2: ¿Cómo se deben descongelar los canapes?

Respuesta generada por LECHAT

TFM

Alumna: María Carolina Passarello.



Transcripción.

Descongelar canapés de manera adecuada es crucial para mantener su textura, sabor y seguridad alimentaria. Aquí tienes algunas técnicas recomendadas para descongelar canapés:

1. Descongelación en el Refrigerador

Este es el método más seguro y recomendado.

Pasos:

- 1. Saca los canapés del congelador: Coloca los canapés en una bandeja o plato.
- 2. **Colócalos en el refrigerador:** Pon la bandeja o plato en el refrigerador y deja que los canapés se descongelen lentamente durante varias horas o durante la noche.
- 3. **Revisa regularmente:** Asegúrate de que los canapés no se descongelen demasiado rápido, lo que podría afectar su textura y sabor.

2. Descongelación a Temperatura Ambiente

TFM

Alumna: María Carolina Passarello.

Este método es más rápido, pero debe hacerse con precaución para evitar la proliferación de bacterias.

Pasos:

- 1. Saca los canapés del congelador: Coloca los canapés en una bandeja o plato.
- 2. **Deja a temperatura ambiente:** Coloca la bandeja o plato en un lugar fresco y seco, lejos de fuentes de calor directo.
- 3. **Revisa regularmente:** Asegúrate de que los canapés no se descongelen demasiado rápido y no los dejes a temperatura ambiente por más de 2 horas.

3. Descongelación en el Microondas

Este método es el más rápido, pero debe hacerse con cuidado para evitar que los canapés se calienten demasiado y pierdan su textura.

Pasos:

- Saca los canapés del congelador: Coloca los canapés en un plato apto para microondas.
- 2. **Configura el microondas:** Usa la función de descongelación o ajusta la potencia del microondas a baja.
- 3. **Descongela en intervalos cortos:** Calienta los canapés en intervalos de 30 segundos a 1 minuto, revisando y moviendo los canapés entre cada intervalo para asegurarte de que se descongelen de manera uniforme.

Consejos Adicionales

- No recalientes: Evita recalentar los canapés una vez que se han descongelado, ya que esto puede afectar su textura y sabor.
- **Consume rápidamente:** Una vez descongelados, los canapés deben consumirse lo antes posible para mantener su frescura y seguridad alimentaria.
- Evita la humedad: Si los canapés contienen ingredientes que pueden volverse húmedos al descongelarse, como verduras o quesos, asegúrate de que no se acumule humedad en exceso durante el proceso de descongelación.

Siguiendo estas técnicas, podrás descongelar tus canapés de manera segura y efectiva, manteniendo su calidad y sabor. ¡Buen provecho!

Métricas sin RAG.

```
ROUGE-1 score: Score(precision=0.03117505995203837, recall=0.6190476190476191, fmeasure=0.0593607305936073)
ROUGE-2 score: Score(precision=0.014423076923076924, recall=0.3, fmeasure=0.027522935779816515)
ROUGE-L score: Score(precision=0.02877697841726619, recall=0.5714285714285714, fmeasure=0.0547945205479452)
BERTScore - Precision: 0.6056541800498962, Recall: 0.712826669216156, F1: 0.6548846960067749
```

Análisis de las métricas.

1. ROUGE-1 Score:

- **Precision**: 0.031 indica que solo el 3.1% de las palabras generadas por el sistema coinciden con las palabras relevantes en el texto de referencia.
- Recall: 0.619 sugiere que el sistema recupera el 61.9% de las palabras relevantes, lo que indica que captura una buena cantidad de contenido, pero con poca precisión.
- F1-Score: 0.059 refleja un balance bajo entre precisión y recall, sugiriendo que aunque el sistema recupera muchas palabras relevantes, la mayoría del contenido generado es irrelevante.

2. ROUGE-2 Score:

- o **Precision**: 0.014 significa que solo el 1.4% de los bigrams generados coinciden con los del texto de referencia.
- o **Recall**: 0.3 indica que el sistema recupera el 30% de los bigrams relevantes.
- F1-Score: 0.028 refleja un bajo rendimiento, lo que sugiere que las secuencias de palabras generadas son muy diferentes de las del texto de referencia.

3. ROUGE-L Score:

- Precision: 0.029 indica que solo el 2.9% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias con el texto de referencia
- o **Recall**: 0.571 significa que el sistema captura el 57.1% de la secuencia relevante más larga.
- **F1-Score**: 0.055 refleja un bajo rendimiento en términos de mantener la estructura del texto de referencia.

4. **BERTScore**:

- **Precision**: 0.606 muestra que el 60.6% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.713 indica que el sistema captura el 71.3% del contenido semántico relevante.
- F1-Score: 0.655 sugiere que, aunque el sistema tiene dificultades con la correspondencia literal, las respuestas generadas son moderadamente coherentes desde un punto de vista semántico.

Conclusión: Las métricas ROUGE reflejan un rendimiento bastante bajo, con precisión extremadamente baja y un recall relativamente alto. Esto sugiere que el sistema genera mucho contenido irrelevante, aunque logra recuperar algunas palabras clave. El BERTScore, sin embargo, muestra una mejor alineación semántica, lo que indica que, aunque el texto generado no es similar en cuanto a palabras o secuencias, el sistema capta algo del significado general. En resumen, el sistema necesita mejorar considerablemente en la generación de contenido relevante y estructurado.

Respuesta esperada (en las tres implementaciones es la misma respuesta):

Nunca sacar los canapés del freezer a temperatura ambiente. Siempre descongelar previamente en heladera para que no condensen y transpiren.

TFM

Alumna: María Carolina Passarello.

Respuesta generada con RAG Básico:

Los canapés deben descongelarse en la heladera. Los canapés fríos deben ser descongelados en la heladera y luego se decoran antes de ser servidos. Los canapés calientes, en cambio, no deben descongelarse en la heladera; deben ser llevados directamente del freezer al horno y luego ser servidos. Nunca se deben sacar los canapés del freezer a temperatura ambiente; siempre deben descongelarse previamente en la heladera para evitar que condensen y transpiren.

Metricas:

```
ROUGE-1 score: Score(precision=0.2631578947368421, recall=0.9523809523809523, fmeasure=0.4123711340206186)
ROUGE-2 score: Score(precision=0.1733333333333333334, recall=0.65, fmeasure=0.2736842105263158)
ROUGE-L score: Score(precision=0.25, recall=0.9047619047619048, fmeasure=0.3917525773195877)
BERTScore - Precision: 0.7553148865699768, Recall: 0.8580218553543091, F1: 0.8033990859985352
```

Análisis de las Métricas

1. **ROUGE-1 Score**:

- o **Precision**: 0.263 indica que el 26.3% de las palabras generadas son relevantes en comparación con el texto de referencia.
- o **Recall**: 0.952 muestra que el sistema recupera el 95.2% de las palabras relevantes, lo que indica que es muy exhaustivo.
- F1-Score: 0.412 refleja un desequilibrio entre precisión y recall, donde el sistema captura muchas palabras clave, pero a costa de incluir contenido irrelevante.

2. ROUGE-2 Score:

- Precision: 0.173 sugiere que solo el 17.3% de los bigrams generados son correctos en comparación con el texto de referencia.
- Recall: 0.65 indica que el sistema recupera el 65% de los bigrams relevantes.
- **F1-Score**: 0.274 refleja un rendimiento moderado en la captura de secuencias de palabras significativas, con una precisión bastante baja.

3. ROUGE-L Score:

- o **Precision**: 0.25 significa que el 25% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.905 indica que el sistema recupera el 90.5% de la secuencia relevante más larga.
- F1-Score: 0.392 muestra un desequilibrio entre precisión y recall, con una alta capacidad de recuperación, pero menor exactitud en las coincidencias largas.

4. **BERTScore**:

- o **Precision**: 0.755 muestra que el 75.5% de las palabras generadas son semánticamente relevantes.
- Recall: 0.858 indica que el sistema captura el 85.8% del contenido semántico importante.

 F1-Score: 0.803 refleja un buen equilibrio entre precisión y recall, lo que indica que las respuestas generadas tienen una buena correspondencia semántica con el texto de referencia.

Conclusión: Las métricas ROUGE sugieren que el sistema tiene un alto recall (recupera la mayoría de las palabras y secuencias relevantes), pero a costa de una precisión más baja, lo que significa que el sistema genera bastante contenido irrelevante. El BERTScore, por otro lado, muestra una buena correspondencia semántica, lo que indica que, aunque el contenido generado no coincide de manera exacta, el sistema es capaz de captar el significado general de las respuestas con precisión.

Respuesta generada con RAG con Haystack:

Los canapés fríos deben ser descongelados en la heladera. Luego se decoran y se sacan a último momento al salón, a excepción de los que son a base de mantecas compuestas que deben ser retirados 20 minutos antes de la heladera para ser servidos. Nunca sacar los canapés del freezer a temperatura ambiente. Siempre descongelar previamente en heladera para que no condensen y transpiren. Los canapés calientes se arman y deben ser congelados inmediatamente. A diferencia de los canapés fríos, no deben descongelarse en la heladera sino, deben ser llevados del freezer al horno directamente y luego ser servidos.

Métricas:

```
ROUGE-1 score: Score(precision=0.19626168224299065, recall=1.0, fmeasure=0.328125)

ROUGE-2 score: Score(precision=0.18867924528301888, recall=1.0, fmeasure=0.3174603174603175)

ROUGE-L score: Score(precision=0.19626168224299065, recall=1.0, fmeasure=0.328125)

BERTScore - Precision: 0.7288983464241028, Recall: 0.8833750486373901, F1: 0.7987362146377563
```

Análisis de las Métricas

1. **ROUGE-1 Score**:

- Precision: 0.196 indica que solo el 19.6% de las palabras generadas por el sistema son relevantes en comparación con el texto de referencia.
- **Recall**: 1.0 significa que el sistema ha capturado el 100% de las palabras relevantes, lo cual indica que es muy exhaustivo.
- F1-Score: 0.328 refleja un fuerte desequilibrio, donde el sistema tiene un recall perfecto, pero genera muchas palabras irrelevantes, lo que reduce la precisión.

2. **ROUGE-2 Score**:

- o **Precision**: 0.189 sugiere que el 18.9% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 1.0 indica que el sistema ha recuperado todos los bigrams relevantes.
- **F1-Score**: 0.317 refleja una baja precisión y un recall perfecto, lo que indica que se generan muchas secuencias irrelevantes.

3. ROUGE-L Score:

- o **Precision**: 0.196 muestra que solo el 19.6% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 1.0 indica que el sistema recupera todas las coincidencias relevantes en la secuencia más larga.
- o **F1-Score**: 0.328 refleja un rendimiento similar al de ROUGE-1, con una gran cantidad de contenido irrelevante generado.

4. BERTScore:

- o **Precision**: 0.729 indica que el 72.9% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.883 sugiere que el sistema captura el 88.3% del contenido semántico relevante.
- F1-Score: 0.799 refleja un buen balance entre precisión y recall, lo que indica que las respuestas generadas son semánticamente coherentes y alineadas con el texto de referencia.

Conclusión: Las métricas ROUGE muestran que el sistema tiene un recall perfecto (captura todo el contenido relevante), pero su precisión es muy baja, lo que indica que se genera mucho contenido irrelevante. En cambio, el BERTScore sugiere una mejor alineación semántica, con un buen balance entre precisión y recall, lo que significa que, aunque el sistema genera mucho contenido adicional, es capaz de captar el significado general del texto con una precisión razonablemente alta.

Respuesta generada con RAG con LLamaIndex

Los canapés fríos deben ser descongelados en la heladera, luego se decoran y se sacan a último momento al salón. Los canapés a base de mantecas compuestas deben ser retirados 20 minutos antes de la heladera para ser servidos. Los canapés calientes, en cambio, no deben descongelarse en la heladera; deben ser llevados directamente del freezer al horno y luego ser servidos. Nunca se deben sacar los canapés del freezer a temperatura ambiente; siempre deben descongelarse previamente en la heladera para evitar que condensen y transpiren.

Métricas

```
ROUGE-1 score: Score(precision=0.21739130434782608, recall=0.9523809523809523, fmeasure=0.3539823008849557)
ROUGE-2 score: Score(precision=0.14285714285714285, recall=0.65, fmeasure=0.23423423423423423)
ROUGE-L score: Score(precision=0.20652173913043478, recall=0.9047619047619048, fmeasure=0.336283185840708)
BERTScore - Precision: 0.7336306571960449, Recall: 0.8489454388618469, F1: 0.7870868444442749
```

Análisis de las Métricas

1. ROUGE-1 Score:

- Precision: 0.217 sugiere que el 21.7% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.952 indica que el sistema recupera el 95.2% de las palabras relevantes, mostrando que es muy exhaustivo.

 F1-Score: 0.354 refleja un desequilibrio, donde el sistema tiene un alto recall, pero una precisión baja, lo que significa que genera bastante contenido irrelevante.

2. ROUGE-2 Score:

- o **Precision**: 0.143 indica que solo el 14.3% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 0.65 significa que el sistema recupera el 65% de los bigrams relevantes.
- o **F1-Score**: 0.234 refleja un rendimiento moderado, con un recall significativamente mejor que la precisión.

3. ROUGE-L Score:

- o **Precision**: 0.207 muestra que el 20.7% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.905 indica que el sistema captura el 90.5% de la secuencia relevante más larga.
- o **F1-Score**: 0.336 refleja un rendimiento similar a ROUGE-1, con un gran desequilibrio entre precisión y recall.

4. **BERTScore**:

- o **Precision**: 0.734 indica que el 73.4% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.849 sugiere que el sistema captura el 84.9% del contenido semántico relevante.
- F1-Score: 0.787 refleja un buen balance entre precisión y recall, indicando que las respuestas generadas están bastante bien alineadas con el significado del texto de referencia.

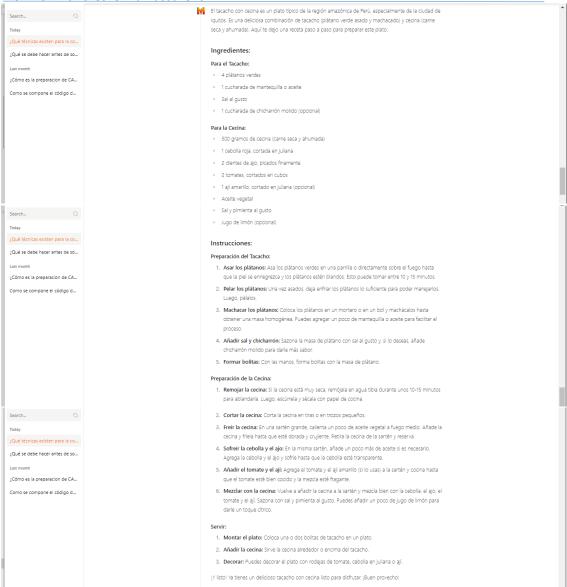
Conclusión: Las métricas ROUGE indican que el sistema tiene un alto recall, recuperando la mayoría del contenido relevante, pero una precisión baja, lo que significa que genera mucho contenido irrelevante. En cambio, el BERTScore muestra una mejor correspondencia semántica, con un buen equilibrio entre precisión y recall, lo que sugiere que el sistema es capaz de captar bien el significado del texto, a pesar de la falta de exactitud en la generación de palabras o secuencias literales.

Pregunta 3 ¿Cómo se prepara el tacacho con cecina?

Respuesta generada por LECHAT

TFM

Alumna: María Carolina Passarello.



Transcripción.

El tacacho con cecina es un plato típico de la región amazónica de Perú, especialmente de la ciudad de Iquitos. Es una deliciosa combinación de tacacho (plátano verde asado y machacado) y cecina (carne seca y ahumada). Aquí te dejo una receta paso a paso para preparar este plato:

Ingredientes:

Para el Tacacho:

- 4 plátanos verdes
- 1 cucharada de mantequilla o aceite
- Sal al gusto
- 1 cucharada de chicharrón molido (opcional)

Para la Cecina:

• 500 gramos de cecina (carne seca y ahumada)

- 1 cebolla roja, cortada en juliana
- 2 dientes de ajo, picados finamente
- 2 tomates, cortados en cubos
- 1 ají amarillo, cortado en juliana (opcional)
- Aceite vegetal
- Sal y pimienta al gusto
- Jugo de limón (opcional)

Instrucciones:

Preparación del Tacacho:

- Asar los plátanos: Asa los plátanos verdes en una parrilla o directamente sobre el fuego hasta que la piel se ennegrezca y los plátanos estén blandos. Esto puede tomar entre 10 y 15 minutos.
- 2. **Pelar los plátanos:** Una vez asados, deja enfriar los plátanos lo suficiente para poder manejarlos. Luego, pélalos.
- 3. **Machacar los plátanos:** Coloca los plátanos en un mortero o en un bol y machácalos hasta obtener una masa homogénea. Puedes agregar un poco de mantequilla o aceite para facilitar el proceso.
- 4. **Añadir sal y chicharrón:** Sazona la masa de plátano con sal al gusto y, si lo deseas, añade chicharrón molido para darle más sabor.
- 5. Formar bolitas: Con las manos, forma bolitas con la masa de plátano.

Preparación de la Cecina:

- 1. **Remojar la cecina:** Si la cecina está muy seca, remójala en agua tibia durante unos 10-15 minutos para ablandarla. Luego, escúrrela y sécala con papel de cocina.
- 2. **Cortar la cecina:** Corta la cecina en tiras o en trozos pequeños.
- 3. **Freír la cecina:** En una sartén grande, calienta un poco de aceite vegetal a fuego medio. Añade la cecina y fríela hasta que esté dorada y crujiente. Retira la cecina de la sartén y reserva.
- 4. **Sofreír la cebolla y el ajo:** En la misma sartén, añade un poco más de aceite si es necesario. Agrega la cebolla y el ajo y sofríe hasta que la cebolla esté transparente.
- 5. **Añadir el tomate y el ají:** Agrega el tomate y el ají amarillo (si lo usas) a la sartén y cocina hasta que el tomate esté bien cocido y la mezcla esté fragante.
- 6. **Mezclar con la cecina:** Vuelve a añadir la cecina a la sartén y mezcla bien con la cebolla, el ajo, el tomate y el ají. Sazona con sal y pimienta al gusto. Puedes añadir un poco de jugo de limón para darle un toque cítrico.

Servir:

TFM

Alumna: María Carolina Passarello.

- 1. Montar el plato: Coloca una o dos bolitas de tacacho en un plato.
- 2. **Añadir la cecina:** Sirve la cecina alrededor o encima del tacacho.
- 3. Decorar: Puedes decorar el plato con rodajas de tomate, cebolla en juliana o ají.

¡Y listo! Ya tienes un delicioso tacacho con cecina listo para disfr

Métricas sin RAG.

```
ROUGE-1 score: Score(precision=0.08623853211009175, recall=0.5949367088607594, fmeasure=0.15064102564102566)
ROUGE-2 score: Score(precision=0.029411764705882353, recall=0.20512820512820512, fmeasure=0.05144694533762057)
ROUGE-L score: Score(precision=0.05504587155963303, recall=0.379746835443038, fmeasure=0.09615384615384616)
BERTScore - Precision: 0.6615914106369019, Recall: 0.7344694137573242, F1: 0.6961281895637512
```

Análisis de las métricas.

1. **ROUGE-1 Score**:

- o **Precision**: 0.086 indica que solo el 8.6% de las palabras generadas son relevantes en comparación con el texto de referencia.
- Recall: 0.595 significa que el sistema captura el 59.5% de las palabras relevantes, lo que sugiere que, aunque recupera algunas palabras clave, la precisión es muy baja.
- F1-Score: 0.151 refleja un bajo equilibrio entre precisión y recall, mostrando que, aunque captura algunas palabras relevantes, la mayoría del contenido generado no es relevante.

2. ROUGE-2 Score:

- o **Precision**: 0.029 sugiere que solo el 2.9% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 0.205 indica que el sistema recupera el 20.5% de los bigrams relevantes.
- **F1-Score**: 0.051 muestra un rendimiento muy bajo en la generación de secuencias de palabras significativas.

3. ROUGE-L Score:

- o **Precision**: 0.055 indica que el 5.5% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.38 significa que el sistema captura el 38% de la secuencia relevante más larga.
- F1-Score: 0.096 refleja un bajo rendimiento general en términos de estructurar correctamente el texto generado en comparación con el texto de referencia.

4. BERTScore:

- o **Precision**: 0.662 muestra que el 66.2% de las palabras generadas son semánticamente relevantes.
- Recall: 0.734 sugiere que el sistema captura el 73.4% del contenido semántico relevante.

TFM

Alumna: María Carolina Passarello.

o **F1-Score**: 0.696 refleja un rendimiento semántico moderadamente bueno, lo que indica que, aunque el sistema no es preciso en cuanto a la estructura o palabras específicas, captura bien el significado general.

Conclusión: Las métricas ROUGE muestran un rendimiento bajo, con una precisión muy baja y un recall moderado, lo que sugiere que el sistema genera mucho contenido irrelevante y tiene dificultades para capturar secuencias de palabras importantes. El BERTScore es considerablemente mejor, indicando que el sistema tiene una buena alineación semántica, aunque no logra capturar de manera precisa las palabras o estructuras exactas del texto de referencia.

Respuesta esperada (en las tres implementaciones es la misma respuesta):

El plato consiste en dos bolas de tacacho (El término «tacacho» derivaría del quechua «taka chu», que significa «lo golpeado». Se prepara una masa compuesta de plátano verde machacado, manteca disuelta, con pequeños trocitos de chicharrón de cerdo y especias

propias de la amazonía. Los plátanos previamente han sido asados en carbón aunque en algunas regiones, como Huánuco, se cocinan en agua), una pieza de cecina y una de chorizo.

Respuesta generada con RAG Básico:

El tacacho con cecina es un plato típico de la Amazonía peruana. Se prepara de la siguiente manera:

- 1. **Preparación del Tacacho**:
- El término «tacacho» deriva del quechua «taka chu», que significa «lo golpeado».
- Se prepara una masa compuesta de plátano verde machacado, manteca disuelta, con pequeños trocitos de chicharrón de cerdo y especias propias de la amazonía.
- Los plátanos previamente han sido asados en carbón, aunque en algunas regiones, como Huánuco, se cocinan en agua.
- 2. **Acompañamiento**:
 - El plato consiste en dos bolas de tacacho.
 - Se acompaña con una pieza de cecina y una de chorizo.

Este plato es una combinación de sabores y texturas que reflejan la riqueza culinaria de la región amazónica.

Métricas

```
ROUGE-1 score: Score(precision=0.5954198473282443, recall=0.9873417721518988, fmeasure=0.7428571428571428) ROUGE-2 score: Score(precision=0.5692307692307692, recall=0.9487179487179487, fmeasure=0.7115384615384616) ROUGE-L score: Score(precision=0.5572519083969466, recall=0.9240506329113924, fmeasure=0.6952380952380953) BERTScore - Precision: 0.7706317901611328, Recall: 0.860222339630127, F1: 0.8129662871360779
```

Análisis de las Métricas

1. **ROUGE-1 Score**:

- o **Precision**: 0.595 indica que el 59.5% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.987 significa que el sistema recupera el 98.7% de las palabras relevantes, lo que indica una alta exhaustividad.
- F1-Score: 0.743 refleja un buen equilibrio entre precisión y recall, lo que sugiere que el sistema no solo recupera la mayoría de las palabras relevantes, sino que lo hace con buena precisión.

2. ROUGE-2 Score:

- o **Precision**: 0.569 indica que el 56.9% de los bigrams generados son correctos en comparación con el texto de referencia.
- **Recall**: 0.949 significa que el sistema recupera el 94.9% de los bigrams relevantes.
- o **F1-Score**: 0.712 muestra que el sistema tiene un buen rendimiento en la captura de secuencias de palabras significativas, con un equilibrio sólido entre precisión y recall.

3. ROUGE-L Score:

- o **Precision**: 0.557 indica que el 55.7% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.924 muestra que el sistema recupera el 92.4% de la secuencia relevante más larga.
- o **F1-Score**: 0.695 refleja un buen rendimiento general en términos de mantener la estructura del texto de referencia.

4. BERTScore:

- o **Precision**: 0.771 indica que el 77.1% de las palabras generadas son semánticamente relevantes.
- o **Recall**: 0.860 sugiere que el sistema captura el 86% del contenido semántico relevante.
- **F1-Score**: 0.813 refleja un buen balance entre precisión y recall, lo que indica que las respuestas generadas están bien alineadas semánticamente con el texto de referencia.

Conclusión: Las métricas ROUGE muestran que el sistema tiene un alto recall, recuperando la mayoría de las palabras y secuencias relevantes, con una precisión sólida que mejora significativamente la calidad de las respuestas. El BERTScore confirma que las respuestas generadas son semánticamente coherentes y precisas, con una correspondencia efectiva con el significado del texto de referencia. En general, el sistema tiene un rendimiento fuerte tanto en términos de coincidencia literal como semántica.

Respuesta generada con RAG con Haystack:

Para preparar el Tacacho con cecina, sigue estos pasos:

Ingredientes:

- Plátano verde
- Manteca de cerdo
- Chicharrón de cerdo
- Especias propias de la amazonía
- Cecina
- Chorizo (opcional)

TFM

Alumna: María Carolina Passarello.

Preparación:

- 1. **Preparación del Tacacho:**
- Asa los plátanos verdes en carbón o, en algunas regiones, cocínalos en aqua.
 - Una vez asados, machaca los plátanos hasta formar una masa.
- Mezcla la masa de plátano con manteca disuelta, chicharrón de cerdo en trocitos pequeños y especias propias de la amazonía.
 - Forma bolas con la masa resultante.
- 2. **Preparación de la Cecina:**
 - Cocina la cecina según tu preferencia, ya sea asada o frita.
- 3. **Presentación:**
 - Sirve las bolas de tacacho acompañadas de una pieza de cecina.
 - Opcionalmente, puedes añadir una pieza de chorizo.

Notas:

- El tacacho es un plato típico de la cocina de la selva peruana, que se prepara con plátano verde sancochado (conocido como "ingiri") y se sirve con cecina y, a veces, chorizo.

 La cecina es una carne salada y secada, típica de la región
- La cecina es una carne salada y secada, típica de la región amazónica.

Este plato es una delicia de la gastronomía peruana y es muy apreciado en la región de la selva. ¡Disfruta de tu Tacacho con cecina!

Métricas.

ROUGE-1 score: Score(precision=0.2830188679245283, recall=0.759493670886076, fmeasure=0.4123711340206186) ROUGE-2 score: Score(precision=0.14691943127962084, recall=0.3974358974358974, fmeasure=0.21453287197231832) ROUGE-L score: Score(precision=0.1650943396226415, recall=0.4430379746835443, fmeasure=0.24054982817869416) BERTScore - Precision: 0.6366279721260071, Recall: 0.7135087251663208, F1: 0.6728793978691101

Análisis de las Métricas:

1. ROUGE-1 Score:

- o **Precision**: 0.283 indica que el 28.3% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.759 significa que el sistema recupera el 75.9% de las palabras relevantes, lo que indica que es relativamente exhaustivo.
- F1-Score: 0.412 muestra un equilibrio moderado entre precisión y recall, lo que indica que, aunque el sistema es capaz de recuperar muchas palabras relevantes, su precisión es baja.

2. ROUGE-2 Score:

- o **Precision**: 0.147 sugiere que solo el 14.7% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 0.397 indica que el sistema recupera el 39.7% de los bigrams relevantes.

 F1-Score: 0.215 refleja un rendimiento moderadamente bajo en la generación de secuencias de palabras significativas, con una precisión baja.

3. ROUGE-L Score:

- o **Precision**: 0.165 muestra que el 16.5% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.443 sugiere que el sistema captura el 44.3% de la secuencia relevante más larga.
- F1-Score: 0.241 indica que el rendimiento del sistema en términos de estructurar las respuestas es bajo, con una baja precisión y recall moderado.

4. BERTScore:

- **Precision**: 0.637 indica que el 63.7% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.714 sugiere que el sistema captura el 71.4% del contenido semántico relevante.
- F1-Score: 0.673 refleja un rendimiento moderado en cuanto a correspondencia semántica, con un equilibrio aceptable entre precisión y recall.

Conclusión: Las métricas ROUGE sugieren que el sistema tiene un recall moderado, lo que indica que captura una cantidad decente de palabras y secuencias relevantes, pero con una baja precisión, lo que significa que genera bastante contenido irrelevante. El BERTScore sugiere que, aunque el sistema no es muy preciso en términos de estructura o palabras exactas, logra capturar parte del significado general con una moderada alineación semántica. En general, el sistema necesita mejorar en la precisión para generar respuestas más exactas y relevantes.

Respuesta generada con RAG con LLamaIndex

El tacacho con cecina es un plato que consiste en dos bolas de tacacho, una pieza de cecina y una de chorizo. El tacacho se prepara con una masa compuesta de plátano verde machacado, manteca disuelta, pequeños trocitos de chicharrón de cerdo y especias propias de la amazonía. Los plátanos previamente han sido asados en carbón, aunque en algunas regiones, como Huánuco, se cocinan en agua.

Métricas

Análisis de las Métricas

1. **ROUGE-1 Score**:

- o **Precision**: 0.932 indica que el 93.2% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.861 significa que el sistema recupera el 86.1% de las palabras relevantes.
- F1-Score: 0.895 refleja un excelente equilibrio entre precisión y recall, lo que sugiere que el sistema genera palabras muy relevantes con gran exactitud.

2. ROUGE-2 Score:

- o **Precision**: 0.792 muestra que el 79.2% de los bigrams generados son correctos en comparación con el texto de referencia.
- **Recall**: 0.731 indica que el sistema recupera el 73.1% de los bigrams relevantes.
- F1-Score: 0.760 refleja un buen equilibrio entre precisión y recall para las secuencias de dos palabras, lo que sugiere una buena capacidad de capturar secuencias significativas.

3. ROUGE-L Score:

- Precision: 0.795 indica que el 79.5% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias con el texto de referencia.
- **Recall**: 0.734 significa que el sistema captura el 73.4% de la secuencia relevante más larga.
- o **F1-Score**: 0.763 refleja un buen equilibrio en términos de mantener la estructura del texto de referencia.

4. BERTScore:

- **Precision**: 0.873 muestra que el 87.3% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.831 sugiere que el sistema captura el 83.1% del contenido semántico relevante.
- F1-Score: 0.852 refleja un excelente equilibrio entre precisión y recall, indicando que las respuestas generadas están bien alineadas semánticamente con el texto de referencia.

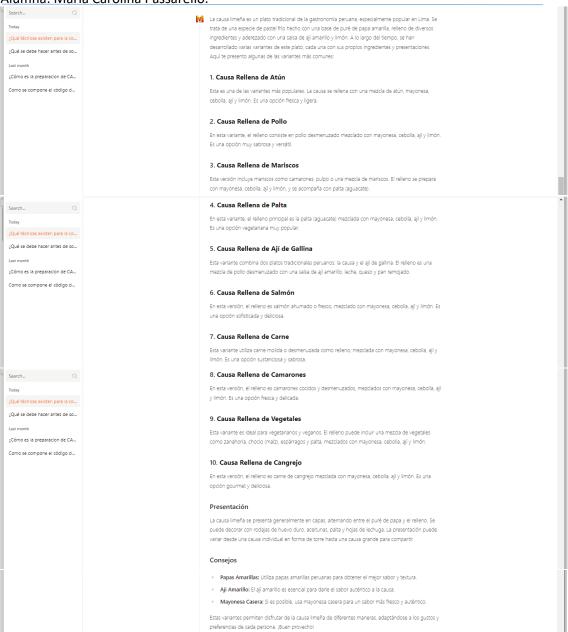
Conclusión: Las métricas ROUGE y BERTScore indican que el sistema tiene un rendimiento muy fuerte tanto en términos de coincidencia literal como de correspondencia semántica. La alta precisión sugiere que el sistema genera respuestas muy relevantes y exactas, mientras que el recall sólido asegura que se captura una gran parte del contenido relevante. Las respuestas generadas no solo coinciden bien con las palabras y secuencias del texto de referencia, sino que también son coherentes desde el punto de vista semántico.

Pregunta 4: ¿Cuáles son las variantes del plato causa a la limeña o causa limeña?

Respuesta generada por LECHAT

TFM

Alumna: María Carolina Passarello.



Transcripción.

La causa limeña es un plato tradicional de la gastronomía peruana, especialmente popular en Lima. Se trata de una especie de pastel frío hecho con una base de puré de papa amarilla, relleno de diversos ingredientes y aderezado con una salsa de ají amarillo y limón. A lo largo del tiempo, se han desarrollado varias variantes de este plato, cada una con sus propios ingredientes y presentaciones. Aquí te presento algunas de las variantes más comunes:

1. Causa Rellena de Atún

Esta es una de las variantes más populares. La causa se rellena con una mezcla de atún, mayonesa, cebolla, ají y limón. Es una opción fresca y ligera.

TFM

Alumna: María Carolina Passarello.

2. Causa Rellena de Pollo

En esta variante, el relleno consiste en pollo desmenuzado mezclado con mayonesa, cebolla, ají y limón. Es una opción muy sabrosa y versátil.

3. Causa Rellena de Mariscos

Esta versión incluye mariscos como camarones, pulpo o una mezcla de mariscos. El relleno se prepara con mayonesa, cebolla, ají y limón, y se acompaña con palta (aguacate).

4. Causa Rellena de Palta

En esta variante, el relleno principal es la palta (aguacate) mezclada con mayonesa, cebolla, ají y limón. Es una opción vegetariana muy popular.

5. Causa Rellena de Ají de Gallina

Esta variante combina dos platos tradicionales peruanos: la causa y el ají de gallina. El relleno es una mezcla de pollo desmenuzado con una salsa de ají amarillo, leche, queso y pan remojado.

6. Causa Rellena de Salmón

En esta versión, el relleno es salmón ahumado o fresco, mezclado con mayonesa, cebolla, ají y limón. Es una opción sofisticada y deliciosa.

7. Causa Rellena de Carne

Esta variante utiliza carne molida o desmenuzada como relleno, mezclada con mayonesa, cebolla, ají y limón. Es una opción sustanciosa y sabrosa.

8. Causa Rellena de Camarones

En esta versión, el relleno es camarones cocidos y desmenuzados, mezclados con mayonesa, cebolla, ají y limón. Es una opción fresca y delicada.

9. Causa Rellena de Vegetales

Esta variante es ideal para vegetarianos y veganos. El relleno puede incluir una mezcla de vegetales como zanahoria, choclo (maíz), espárragos y palta, mezclados con mayonesa, cebolla, ají y limón.

10. Causa Rellena de Cangrejo

En esta versión, el relleno es carne de cangrejo mezclada con mayonesa, cebolla, ají y limón. Es una opción gourmet y deliciosa.

Presentación

La causa limeña se presenta generalmente en capas, alternando entre el puré de papa y el relleno. Se puede decorar con rodajas de huevo duro, aceitunas, palta y hojas de lechuga. La presentación puede variar desde una causa individual en forma de torre hasta una causa grande para compartir.

Consejos

TFM

Alumna: María Carolina Passarello.

- Papas Amarillas: Utiliza papas amarillas peruanas para obtener el mejor sabor y textura.
- Ají Amarillo: El ají amarillo es esencial para darle el sabor auténtico a la causa.
- Mayonesa Casera: Si es posible, usa mayonesa casera para un sabor más fresco y auténtico.

Estas variantes permiten disfrutar de la causa limeña de diferentes maneras, adaptándose a los gustos y preferencias de cada persona. ¡Buen provecho!

Métricas sin RAG.

```
ROUGE-1 score: Score(precision=0.038817005545286505, recall=0.6774193548387096, fmeasure=0.07342657342657341)
ROUGE-2 score: Score(precision=0.012962962962962963, recall=0.233333333333333334, fmeasure=0.02456140350877193)
ROUGE-L score: Score(precision=0.031423290203327174, recall=0.5483870967741935, fmeasure=0.05944055944055945)
BERTScore - Precision: 0.6170964241027832, Recall: 0.7281724810600281, F1: 0.6680487394332886
```

Análisis de las métricas

1. **ROUGE-1 Score**:

- **Precision**: 0.039 indica que solo el 3.9% de las palabras generadas son relevantes en comparación con el texto de referencia.
- Recall: 0.677 sugiere que el sistema recupera el 67.7% de las palabras relevantes, lo que indica que el sistema tiene una alta exhaustividad pero muy baja precisión.
- **F1-Score**: 0.073 refleja un desequilibrio severo entre precisión y recall, con mucho contenido irrelevante generado.

2. ROUGE-2 Score:

- o **Precision**: 0.013 muestra que solo el 1.3% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 0.233 significa que el sistema recupera el 23.3% de los bigrams relevantes.
- o **F1-Score**: 0.025 indica un rendimiento extremadamente bajo en la captura de secuencias de palabras significativas.

3. ROUGE-L Score:

- o **Precision**: 0.031 indica que solo el 3.1% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.548 sugiere que el sistema recupera el 54.8% de la secuencia relevante más larga.
- **F1-Score**: 0.059 refleja un rendimiento general muy bajo en términos de estructurar correctamente las respuestas.

4. BERTScore:

- o **Precision**: 0.617 muestra que el 61.7% de las palabras generadas son semánticamente relevantes.
- Recall: 0.728 indica que el sistema captura el 72.8% del contenido semántico relevante.

 F1-Score: 0.668 refleja un rendimiento aceptable en cuanto a correspondencia semántica, aunque con margen para mejorar.

Conclusión: Las métricas ROUGE muestran un rendimiento muy bajo, con una precisión extremadamente baja y un recall moderado, lo que indica que el sistema genera mucho contenido irrelevante. Sin embargo, el BERTScore es más favorable, sugiriendo que, aunque el sistema no capta bien las palabras o estructuras exactas, tiene una alineación semántica moderadamente buena, capturando parte del significado general del texto de referencia. El sistema necesita mejorar significativamente en la precisión y en la capacidad para generar respuestas estructuralmente más relevantes.

Respuesta esperada (en las tres implementaciones es la misma respuesta):

Esta preparación admite diversas variantes, como causa rellena de atún, de pollo, de mariscos u otras variedades de carnes blancas. Se sirve con un ligero baño de mayonesa.

Respuesta generada con RAG Básico:

Las variantes del plato causa a la limeña o causa limeña incluyen:

- Causa rellena de atún
- Causa rellena de pollo
- Causa rellena de mariscos
- Otras variedades de carnes blancas

Métricas

Análisis de las Métricas

1. ROUGE-1 Score:

- o **Precision**: 0.5 indica que el 50% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.516 significa que el sistema recupera el 51.6% de las palabras relevantes.
- F1-Score: 0.508 refleja un buen equilibrio entre precisión y recall, lo que indica que el sistema genera una cantidad aceptable de contenido relevante, aunque con espacio para mejorar.

2. ROUGE-2 Score:

- o **Precision**: 0.323 sugiere que el 32.3% de los bigrams generados son correctos en comparación con el texto de referencia.
- **Recall**: 0.333 indica que el sistema recupera el 33.3% de los bigrams relevantes.

TFM

Alumna: María Carolina Passarello.

 F1-Score: 0.328 refleja un rendimiento moderado en la captura de secuencias de palabras significativas, aunque con una precisión algo limitada.

3. **ROUGE-L Score**:

- o **Precision**: 0.469 indica que el 46.9% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.484 muestra que el sistema recupera el 48.4% de la secuencia relevante más larga.
- F1-Score: 0.476 refleja un equilibrio razonable en la captura de las secuencias largas, aunque también hay espacio para mejorar en ambos aspectos.

4. BERTScore:

- o **Precision**: 0.737 indica que el 73.7% de las palabras generadas son semánticamente relevantes.
- o **Recall**: 0.760 sugiere que el sistema captura el 76% del contenido semántico relevante.
- **F1-Score**: 0.748 muestra un buen balance entre precisión y recall en términos de correspondencia semántica.

Conclusión: Las métricas ROUGE indican un rendimiento moderado, con una buena capacidad para generar contenido relevante, pero con margen para mejorar la precisión y el recall, especialmente en las secuencias de palabras significativas. El BERTScore muestra que el sistema tiene una buena alineación semántica, con respuestas que son en su mayoría coherentes con el significado del texto de referencia. Aunque el sistema es razonablemente preciso, aún hay espacio para mejorar tanto la precisión como el recall en términos de la coincidencia literal y estructural.

Respuesta generada con RAG con Haystack:

Las variantes del plato causa a la limeña o causa limeña incluyen:

- Causa rellena de atún
- Causa rellena de pollo
- Causa rellena de mariscos
- Otras variedades de carnes blancas

Estas variantes se sirven con un ligero baño de mayonesa.

Métricas:

Análisis de las Métricas.

1. **ROUGE-1 Score**:

- o **Precision**: 0.558 indica que el 55.8% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.774 muestra que el sistema recupera el 77.4% de las palabras relevantes, lo que indica una buena capacidad de recuperación.
- o **F1-Score**: 0.649 refleja un equilibrio sólido entre precisión y recall, lo que sugiere que el sistema genera una cantidad adecuada de contenido relevante, con un buen balance entre exactitud y exhaustividad.

2. ROUGE-2 Score:

- o **Precision**: 0.381 muestra que el 38.1% de los bigrams generados son correctos en comparación con el texto de referencia.
- **Recall**: 0.533 indica que el sistema recupera el 53.3% de los bigrams relevantes.
- F1-Score: 0.444 refleja un rendimiento razonable en la generación de secuencias de palabras significativas, aunque con margen para mejorar la precisión.

3. ROUGE-L Score:

- o **Precision**: 0.535 indica que el 53.5% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.742 muestra que el sistema captura el 74.2% de la secuencia relevante más larga.
- o **F1-Score**: 0.622 refleja un buen equilibrio en términos de estructurar correctamente las respuestas con relación al texto de referencia.

4. BERTScore:

- o **Precision**: 0.782 muestra que el 78.2% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.837 indica que el sistema captura el 83.7% del contenido semántico relevante.
- **F1-Score**: 0.808 refleja un muy buen balance entre precisión y recall en términos de correspondencia semántica.

Conclusión: Las métricas ROUGE muestran un buen rendimiento global, con un alto recall y una precisión sólida en la generación de palabras y secuencias relevantes, aunque la precisión podría mejorarse en la generación de bigrams. El BERTScore refuerza la idea de que las respuestas generadas son semánticamente coherentes y están bien alineadas con el significado del texto de referencia. El sistema logra un buen equilibrio entre la recuperación de información relevante y su precisión, tanto a nivel literal como semántico.

Respuesta generada con RAG con LlamaIndex

Las variantes del plato causa a la limeña o causa limeña incluyen causa rellena de atún, de pollo, de mariscos y otras variedades de carnes blancas.

Métricas

TFM

Alumna: María Carolina Passarello.

```
ROUGE-L score: Score(precision=0.5172413793103449, recall=0.4838709677419355, fmeasure=0.5000000000000001) BERTScore - Precision: 0.8179948925971985, Recall: 0.8262407183647156, F1: 0.82209712266922
```

Análisis de las Métricas

1. **ROUGE-1 Score**:

- o **Precision**: 0.552 indica que el 55.2% de las palabras generadas son relevantes en comparación con el texto de referencia.
- Recall: 0.516 muestra que el sistema recupera el 51.6% de las palabras relevantes, lo que indica una buena pero no completa capacidad de recuperación.
- F1-Score: 0.533 refleja un equilibrio razonable entre precisión y recall, lo que indica que el sistema es moderadamente efectivo generando contenido relevante.

2. ROUGE-2 Score:

- o **Precision**: 0.429 sugiere que el 42.9% de los bigrams generados son correctos en comparación con el texto de referencia.
- o **Recall**: 0.4 indica que el sistema recupera el 40% de los bigrams relevantes.
- F1-Score: 0.414 refleja un rendimiento moderado en la captura de secuencias de palabras significativas, con una precisión aceptable, pero con margen de mejora.

3. ROUGE-L Score:

- o **Precision**: 0.517 indica que el 51.7% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.484 muestra que el sistema captura el 48.4% de la secuencia relevante más larga.
- **F1-Score**: 0.500 indica un equilibrio razonable, pero muestra que la precisión podría mejorar en la captura de secuencias estructuradas.

4. BERTScore:

- o **Precision**: 0.818 sugiere que el 81.8% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.826 indica que el sistema captura el 82.6% del contenido semántico relevante.
- F1-Score: 0.822 refleja un muy buen equilibrio entre precisión y recall, lo que indica que las respuestas generadas están bien alineadas semánticamente con el texto de referencia.

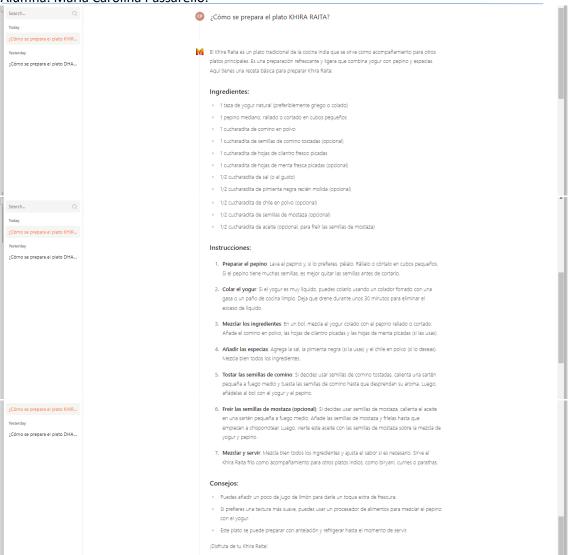
Conclusión: Las métricas ROUGE muestran un rendimiento moderado, con un buen equilibrio entre precisión y recall, pero aún hay espacio para mejorar la precisión y la captura de secuencias más largas. El BERTScore indica que el sistema es semánticamente coherente, capturando bien el significado del texto de referencia, con un rendimiento más fuerte en términos de correspondencia semántica que en términos de coincidencias literales o de secuencias exactas.

Pregunta 5:¿Cómo se prepara el plato KHIRA RAITA?

Respuesta generada por LECHAT

TFM

Alumna: María Carolina Passarello.



Transcripción.

El Khira Raita es un plato tradicional de la cocina india que se sirve como acompañamiento para otros platos principales. Es una preparación refrescante y ligera que combina yogur con pepino y especias. Aquí tienes una receta básica para preparar Khira Raita:

Ingredientes:

- 1 taza de yogur natural (preferiblemente griego o colado)
- 1 pepino mediano, rallado o cortado en cubos pequeños
- 1 cucharadita de comino en polvo
- 1 cucharadita de semillas de comino tostadas (opcional)
- 1 cucharadita de hojas de cilantro fresco picadas
- 1 cucharadita de hojas de menta fresca picadas (opcional)

TFM

Alumna: María Carolina Passarello.

- 1/2 cucharadita de sal (o al gusto)
- 1/2 cucharadita de pimienta negra recién molida (opcional)
- 1/2 cucharadita de chile en polvo (opcional)
- 1/2 cucharadita de semillas de mostaza (opcional)
- 1/2 cucharadita de aceite (opcional, para freír las semillas de mostaza)

Instrucciones:

- 1. **Preparar el pepino**: Lava el pepino y, si lo prefieres, pélalo. Rállalo o córtalo en cubos pequeños. Si el pepino tiene muchas semillas, es mejor quitar las semillas antes de cortarlo.
- 2. **Colar el yogur**: Si el yogur es muy líquido, puedes colarlo usando un colador forrado con una gasa o un paño de cocina limpio. Deja que drene durante unos 30 minutos para eliminar el exceso de líquido.
- 3. **Mezclar los ingredientes**: En un bol, mezcla el yogur colado con el pepino rallado o cortado. Añade el comino en polvo, las hojas de cilantro picadas y las hojas de menta picadas (si las usas).
- 4. **Añadir las especias**: Agrega la sal, la pimienta negra (si la usas) y el chile en polvo (si lo deseas). Mezcla bien todos los ingredientes.
- 5. **Tostar las semillas de comino**: Si decides usar semillas de comino tostadas, calienta una sartén pequeña a fuego medio y tuesta las semillas de comino hasta que desprendan su aroma. Luego, añádelas al bol con el yogur y el pepino.
- 6. **Freír las semillas de mostaza (opcional)**: Si decides usar semillas de mostaza, calienta el aceite en una sartén pequeña a fuego medio. Añade las semillas de mostaza y fríelas hasta que empiecen a chisporrotear. Luego, vierte este aceite con las semillas de mostaza sobre la mezcla de yogur y pepino.
- 7. **Mezclar y servir**: Mezcla bien todos los ingredientes y ajusta el sabor si es necesario. Sirve el Khira Raita frío como acompañamiento para otros platos indios, como biryani, curries o parathas.

Consejos:

- Puedes añadir un poco de jugo de limón para darle un toque extra de frescura.
- Si prefieres una textura más suave, puedes usar un procesador de alimentos para mezclar el pepino con el yogur.
- Este plato se puede preparar con antelación y refrigerar hasta el momento de servir.

¡Disfruta de tu Khira Raita!

Métricas sin RAG.

```
ROUGE-1 score: Score(precision=0.050314465408805034, recall=0.6153846153846154, fmeasure=0.09302325581395349) ROUGE-2 score: Score(precision=0.014705882352941176, recall=0.18421052631578946, fmeasure=0.02723735408560311)
```

TFM

Alumna: María Carolina Passarello.

ROUGE-L score: Score(precision=0.03563941299790356, recall=0.4358974358974359, fmeasure=0.06589147286821705)
BERTScore - Precision: 0.609711229801178, Recall: 0.7024815678596497, F1: 0.6528170108795166

Análisis de las métricas.

1. **ROUGE-1 Score**:

- o **Precision**: 0.050 indica que solo el 5% de las palabras generadas son relevantes en comparación con el texto de referencia.
- Recall: 0.615 sugiere que el sistema recupera el 61.5% de las palabras relevantes, lo que muestra un buen nivel de exhaustividad pero con muy baja precisión.
- o **F1-Score**: 0.093 refleja un **gran desequilibrio** entre precisión y recall, lo que indica que el sistema genera mucho contenido irrelevante.

2. ROUGE-2 Score:

- o **Precision**: 0.015 sugiere que solo el 1.5% de los bigrams generados son correctos en comparación con el texto de referencia.
- **Recall**: 0.184 indica que el sistema recupera el 18.4% de los bigrams relevantes.
- F1-Score: 0.027 refleja un rendimiento muy bajo en la generación de secuencias de palabras significativas, lo que indica que el sistema tiene dificultades en capturar relaciones entre palabras clave.

3. **ROUGE-L Score**:

- o **Precision**: 0.036 muestra que solo el 3.6% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.436 indica que el sistema recupera el 43.6% de la secuencia relevante más larga.
- o **F1-Score**: 0.066 muestra que el sistema tiene dificultades para capturar correctamente las secuencias estructuradas de palabras.

4. BERTScore:

- **Precision**: 0.610 indica que el 61% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.702 sugiere que el sistema captura el 70.2% del contenido semántico relevante.
- F1-Score: 0.653 refleja un rendimiento moderado en términos de correspondencia semántica, aunque el sistema es mucho más efectivo a nivel de significado que en términos de coincidencia literal.

Conclusión: Las métricas ROUGE muestran que el sistema tiene una precisión extremadamente baja, generando mucho contenido irrelevante, aunque el recall es relativamente alto, lo que sugiere que el sistema captura partes importantes del contenido relevante pero de manera muy imprecisa. El BERTScore, por otro lado, indica que el sistema tiene un rendimiento moderado en términos de semántica, capturando el significado general pero con importantes deficiencias en términos de exactitud y estructura. El sistema necesita mejoras considerables en la precisión para generar contenido más relevante y coherente.

Respuesta esperada (en las tres implementaciones es la misma respuesta):

Pelar el pepino y luego quitarle las semillas.

TFM

Alumna: María Carolina Passarello.

Cortarlos en brunoise O bien rallarlo. Colocarlo en un bowl junto a los demás ingredientes y por último incorporar el yogurt y dejar reposar.

Opcional: perfumar con menta fresca picada.

Respuesta generada con RAG Básico:

Para preparar el plato KHIRA RAITA, sigue estos pasos:

Ingredientes:

- Pepino: ½ unidad
- Sal: cantidad necesaria (c/n)
- Ajo: cantidad necesaria (c/n)
- Jengibre fresco rallado: cantidad necesaria (c/n)
- Jugo de limón: cantidad necesaria (c/n)
- Yogurt natural: 0.150 kg

Preparación:

- 1. Pelar el pepino y luego quitarle las semillas.
- 2. Cortar el pepino en brunoise o bien rallarlo.
- 3. Colocar el pepino en un bowl junto a los demás ingredientes (sal, ajo, jengibre fresco rallado y jugo de limón).
- 4. Por último, incorporar el yogurt y dejar reposar.

Opcional:

- Perfumar con menta fresca picada.

Esta preparación es una ensalada fresca aderezada con yogurt, típica de la cocina hindú.

Métricas

```
ROUGE-1 score: Score(precision=0.31896551724137934, recall=0.9487179487179487, fmeasure=0.47741935483870973) ROUGE-2 score: Score(precision=0.2782608695652174, recall=0.8421052631578947, fmeasure=0.41830065359477125) ROUGE-L score: Score(precision=0.31896551724137934, recall=0.9487179487179487, fmeasure=0.47741935483870973) BERTScore - Precision: 0.6851367354393005, Recall: 0.8734524846076965, F1: 0.767918050289154
```

Análisis de las Métricas

1. **ROUGE-1 Score**:

- Precision: 0.319 indica que el 31.9% de las palabras generadas son relevantes en comparación con el texto de referencia.
- o **Recall**: 0.949 muestra que el sistema recupera el 94.9% de las palabras relevantes, lo que refleja una alta exhaustividad.
- F1-Score: 0.477 indica un desequilibrio entre precisión y recall, sugiriendo que, aunque el sistema captura muchas palabras relevantes, genera bastante contenido irrelevante.

2. ROUGE-2 Score:

• **Precision**: 0.278 muestra que el 27.8% de los bigrams generados son correctos en comparación con el texto de referencia.

- **Recall**: 0.842 significa que el sistema recupera el 84.2% de los bigrams relevantes.
- o **F1-Score**: 0.418 refleja que el sistema tiene **buen recall** en las secuencias de palabras, pero la precisión sigue siendo baja.

3. ROUGE-L Score:

- o **Precision**: 0.319 refleja que el 31.9% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.949, al igual que en ROUGE-1, muestra que el sistema es muy exhaustivo en capturar la secuencia relevante más larga.
- o **F1-Score**: 0.477 refleja un rendimiento similar al de ROUGE-1, destacando que el sistema es exhaustivo pero con **baja precisión**.

4. BERTScore:

- **Precision**: 0.685 indica que el 68.5% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.873 sugiere que el sistema captura el 87.3% del contenido semántico relevante.
- **F1-Score**: 0.768 refleja un buen balance entre precisión y recall en términos de correspondencia semántica.

Conclusión: Las métricas ROUGE indican que el sistema tiene un alto recall (captura la mayoría del contenido relevante) pero una precisión moderada, lo que significa que también genera una cantidad significativa de contenido irrelevante. El BERTScore muestra que el sistema tiene una buena alineación semántica, lo que indica que, a nivel de significado, las respuestas son mayormente coherentes. Sin embargo, la precisión literal y estructural puede mejorarse para generar contenido más exacto y menos redundante.

Respuesta generada con RAG con Haystack:

Para preparar el plato KHIRA RAITA, sique estos pasos:

```
### Ingredientes:
```

- ½ pepino
- Sal al gusto
- Ajo al gusto
- Jengibre fresco rallado al gusto
- Jugo de limón al gusto
- Yogurt natural 0.150 kg

Preparación:

- 1. **Pelar y quitar las semillas del pepino**: Comienza pelando el pepino y luego quítale las semillas.
- 2. **Cortar el pepino**: Corta el pepino en brunoise (pequeños cubos) o bien rállalo.
- 3. **Mezclar los ingredientes**: Coloca el pepino cortado o rallado en un bowl junto con el ajo, el jengibre fresco rallado, el jugo de limón y la sal al gusto.
- 4. **Incorporar el yogurt**: Por último, incorpora el yogurt natural al bowl y mezcla bien todos los ingredientes.
- 5. **Dejar reposar**: Deja reposar la mezcla para que los sabores se integren.

Opcional:

TFM

Alumna: María Carolina Passarello.

- **Perfumar con menta fresca picada**: Si deseas, puedes agregar menta fresca picada para darle un toque adicional de sabor.

Este plato es una ensalada fresca aderezada con yogurt, ideal para acompañar platos picantes de la cocina india.

Métricas:

ROUGE-1 score: Score(precision=0.18823529411764706, recall=0.8205128205128205, fmeasure=0.3062200956937799) ROUGE-2 score: Score(precision=0.10650887573964497, recall=0.47368421052631576, fmeasure=0.17391304347826086) ROUGE-L score: Score(precision=0.17058823529411765, recall=0.7435897435897436, fmeasure=0.277511961722488) BERTScore - Precision: 0.6545002460479736, Recall: 0.799515426158905, F1: 0.7197763323783875

Análisis de las Métricas:

1. **ROUGE-1 Score**:

- o **Precision**: 0.188 indica que el 18.8% de las palabras generadas son relevantes en comparación con el texto de referencia.
- o **Recall**: 0.821 sugiere que el sistema recupera el 82.1% de las palabras relevantes, lo que muestra una **alta exhaustividad**.
- F1-Score: 0.306 refleja un desequilibrio entre precisión y recall, con una buena capacidad para recuperar contenido relevante, pero incluyendo también mucho contenido irrelevante.

2. ROUGE-2 Score:

- o **Precision**: 0.107 indica que solo el 10.7% de los bigrams generados son correctos en comparación con el texto de referencia.
- **Recall**: 0.474 muestra que el sistema recupera el 47.4% de los bigrams relevantes.
- o **F1-Score**: 0.174 refleja un rendimiento bajo en la generación de secuencias de palabras significativas, con una **baja precisión**.

3. ROUGE-L Score:

- o **Precision**: 0.171 sugiere que el 17.1% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.744 indica que el sistema recupera el 74.4% de la secuencia relevante más larga.
- F1-Score: 0.278 refleja un desequilibrio similar al de ROUGE-1, con alta recuperación pero baja precisión.

4. BERTScore:

- **Precision**: 0.655 indica que el 65.5% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.800 muestra que el sistema captura el 80% del contenido semántico relevante.
- **F1-Score**: 0.720 refleja un **buen equilibrio** entre precisión y recall en términos de **correspondencia semántica**.

Conclusión: Las métricas ROUGE sugieren que el sistema tiene un alto recall (recupera la mayoría del contenido relevante), pero su precisión es baja, lo que indica

TFM

Alumna: María Carolina Passarello.

que genera bastante contenido irrelevante, especialmente en secuencias de palabras. El **BERTScore** muestra que, a nivel **semántico**, el sistema tiene un rendimiento razonablemente bueno, capturando el significado general del texto de referencia. Sin embargo, es necesario mejorar la **precisión** para reducir el contenido irrelevante y mejorar la exactitud tanto en la estructura como en las palabras generadas.

Respuesta generada con RAG con LLamaindex

Para preparar el plato KHIRA RAITA, primero se pela el pepino y se le quitan las semillas. Luego, se corta en brunoise o se ralla. Se coloca en un bowl junto a los demás ingredientes: sal, ajo, jengibre fresco rallado y jugo de limón. Por último, se incorpora el yogurt natural y se deja reposar. Opcionalmente, se puede perfumar con menta fresca picada.

Métricas

```
ROUGE-1 score: Score(precision=0.46153846153846156, recall=0.7692307692307693, fmeasure=0.576923076923077) ROUGE-2 score: Score(precision=0.296875, recall=0.5, fmeasure=0.37254901960784315) ROUGE-L score: Score(precision=0.4461538461538462, recall=0.7435897435897436, fmeasure=0.5576923076923078) BERTScore - Precision: 0.786742627620697, Recall: 0.8509151935577393, F1: 0.8175715208053589
```

Análisis de las Métricas

1. ROUGE-1 Score:

- o **Precision**: 0.462 indica que el 46.2% de las palabras generadas son relevantes en comparación con el texto de referencia.
- o **Recall**: 0.769 muestra que el sistema recupera el 76.9% de las palabras relevantes, lo que sugiere una **alta exhaustividad**.
- o **F1-Score**: 0.577 refleja un **buen equilibrio** entre precisión y recall, lo que indica que el sistema genera una cantidad significativa de contenido relevante, aunque puede incluir algo de contenido irrelevante.

2. ROUGE-2 Score:

- **Precision**: 0.297 indica que el 29.7% de los bigrams generados son correctos en comparación con el texto de referencia.
- **Recall**: 0.5 significa que el sistema recupera el 50% de los bigrams relevantes.
- F1-Score: 0.373 refleja un rendimiento moderado en la captura de secuencias de palabras significativas, con margen para mejorar la precisión.

3. ROUGE-L Score:

- o **Precision**: 0.446 indica que el 44.6% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.744 sugiere que el sistema recupera el 74.4% de la secuencia relevante más larga.
- **F1-Score**: 0.558 refleja un **buen balance** entre precisión y recall en términos de la estructura de las secuencias de palabras.

4. **BERTScore**:

TFM

Alumna: María Carolina Passarello.

- **Precision**: 0.787 muestra que el 78.7% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.851 indica que el sistema captura el 85.1% del contenido semántico relevante.
- **F1-Score**: 0.818 refleja un **excelente equilibrio** entre precisión y recall en términos de correspondencia semántica.

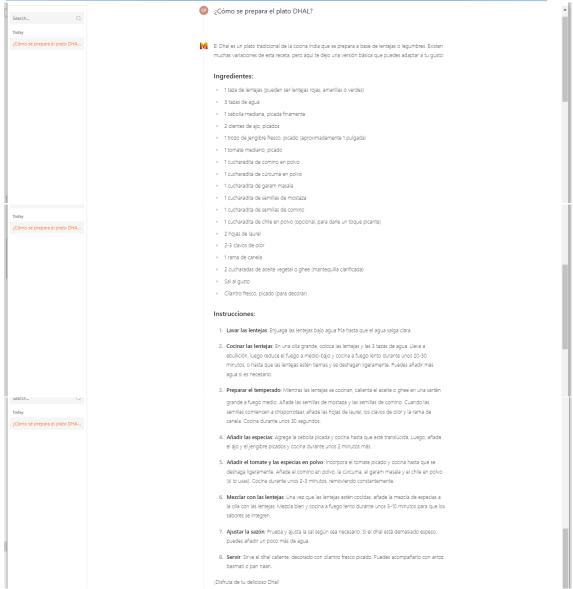
Conclusión: Las métricas ROUGE muestran que el sistema tiene un buen rendimiento general, con un alto recall y una precisión moderada. Esto sugiere que el sistema genera una cantidad considerable de contenido relevante, aunque podría incluir algo de contenido irrelevante, especialmente en las secuencias de palabras. El BERTScore indica una buena alineación semántica, con un excelente balance entre precisión y recall, lo que significa que las respuestas generadas son coherentes y alineadas con el significado general del texto de referencia. El sistema tiene un rendimiento fuerte en términos de significado, pero podría mejorar en la precisión de las secuencias literales.

Pregunta 6:¿Cómo se prepara el plato DHAL?

Respuesta generada por LECHAT

TFM

Alumna: María Carolina Passarello.



Transcripción.

El dhal es un plato tradicional de la cocina india y de otras regiones del sur de Asia. Se trata de un guiso de lentejas o legumbres que puede variar en ingredientes y especias según la región y las preferencias personales. Aquí te dejo una receta básica de dhal que puedes adaptar a tu gusto:

Ingredientes:

Para el Dhal:

- 200 gramos de lentejas amarillas (toor dal) o cualquier otra lenteja de tu preferencia
- 1 cebolla mediana, finamente picada

- 2 dientes de ajo, finamente picados
- 1 trozo de jengibre fresco (aproximadamente 1 pulgada), finamente picado
- 1-2 chiles verdes, finamente picados (opcional)
- 1 tomate mediano, finamente picado
- 1 cucharadita de cúrcuma en polvo
- 1 cucharadita de comino en polvo
- 1 cucharadita de cilantro en polvo
- 1/2 cucharadita de garam masala
- 1/2 cucharadita de semillas de mostaza
- 1/2 cucharadita de semillas de comino
- 1/2 cucharadita de semillas de hinojo (opcional)
- 1/2 cucharadita de semillas de fenogreco (opcional)
- 1 hoja de laurel
- 1-2 hojas de curry (opcional)
- 1 taza de leche de coco (opcional)
- Aceite vegetal o ghee (mantequilla clarificada)
- Sal al gusto
- Cilantro fresco, picado (para decorar)

Para el Tadka (Temperamento):

- 1 cucharada de aceite vegetal o ghee
- 1/2 cucharadita de semillas de mostaza
- 1/2 cucharadita de semillas de comino
- 1/2 cucharadita de semillas de hinojo (opcional)
- 1/2 cucharadita de semillas de fenogreco (opcional)
- 1-2 chiles rojos secos (opcional)

- 1 hoja de laurel
- 1-2 hojas de curry (opcional)
- 1/2 cucharadita de asafétida (hing) en polvo (opcional)

Instrucciones:

Preparación del Dhal:

- 1. Lavar las lentejas: Enjuaga las lentejas bajo agua fría hasta que el agua salga clara.
- 2. Cocinar las lentejas: Coloca las lentejas en una olla grande y cúbrelas con suficiente agua (aproximadamente 3 tazas de agua). Añade una pizca de sal y lleva a ebullición. Reduce el fuego a medio y cocina a fuego lento hasta que las lentejas estén tiernas, aproximadamente 20-30 minutos. Si es necesario, añade más agua durante la cocción.
- 3. **Preparar los ingredientes:** Mientras las lentejas se cocinan, pica la cebolla, el ajo, el jengibre, los chiles verdes y el tomate.
- 4. Sofreír los ingredientes: En una sartén grande, calienta un poco de aceite o ghee a fuego medio. Añade la cebolla y cocina hasta que esté translúcida. Luego, añade el ajo, el jengibre y los chiles verdes y cocina por unos minutos más.
- 5. Añadir las especias: Añade la cúrcuma, el comino en polvo, el cilantro en polvo, el garam masala, las semillas de mostaza, las semillas de comino, las semillas de hinojo (si las usas), las semillas de fenogreco (si las usas), la hoja de laurel y las hojas de curry (si las usas). Cocina durante unos minutos hasta que las especias estén fragantes.
- 6. **Añadir el tomate:** Añade el tomate picado y cocina hasta que se deshaga y se mezcle bien con las especias.

- 7. Mezclar con las lentejas: Una vez que las lentejas estén cocidas, añade la mezcla de cebolla y especias a la olla de lentejas. Mezcla bien y cocina a fuego lento durante unos 10-15 minutos para que los sabores se integren. Si deseas, puedes añadir leche de coco en este punto para darle un toque cremoso.
- 8. **Ajustar la sazón:** Prueba y ajusta la sal y las especias según sea necesario.

Preparación del Tadka (Temperamento):

- 1. Calentar el aceite: En una sartén pequeña, calienta el aceite o ghee a fuego medio.
- 2. Añadir las especias: Añade las semillas de mostaza, las semillas de comino, las semillas de hinojo (si las usas), las semillas de fenogreco (si las usas), los chiles rojos secos (si los usas), la hoja de laurel y las hojas de curry (si las usas). Cocina hasta que las semillas comiencen a chisporrotear.
- 3. **Añadir la asafétida:** Si usas asafétida en polvo, añádela en este punto y cocina por unos segundos más.
- Mezclar con el dhal: Vierte el tadka sobre el dhal y mezcla bien.

Presentación:

- Decorar: Sirve el dhal caliente y decora con cilantro fresco picado.
- Acompañamiento: El dhal se puede servir con arroz basmati, naan (pan indio) o roti.

¡Y listo! Ya tienes un delicioso dhal listo para disfrutar. ¡Buen provecho!

Métricas sin RAG.

ROUGE-1 score: Score(precision=0.056451612903225805, recall=0.6, fmeasure=0.1031941031941032)

ROUGE-2 score: Score(precision=0.012113055181695828, recall=0.13043478260869565, fmeasure=0.02216748768472906)

TFM

Alumna: María Carolina Passarello.

```
ROUGE-L score: Score(precision=0.03763440860215054, recall=0.4, fmeasure=0.0687960687960688)
BERTScore - Precision: 0.5705870389938354, Recall: 0.6519874930381775, F1: 0.6085774302482605
```

Análisis de las métricas.

1. **ROUGE-1 Score**:

- **Precision**: 0.056 indica que solo el 5.6% de las palabras generadas son relevantes en comparación con el texto de referencia.
- Recall: 0.6 sugiere que el sistema recupera el 60% de las palabras relevantes, lo que indica una alta exhaustividad pero con muy baja precisión.
- o **F1-Score**: 0.103 refleja un **desequilibrio severo** entre precisión y recall, donde el sistema genera mucho contenido irrelevante.

2. ROUGE-2 Score:

- o **Precision**: 0.012 muestra que solo el 1.2% de los bigrams generados coinciden con el texto de referencia.
- Recall: 0.13 indica que el sistema recupera el 13% de los bigrams relevantes.
- F1-Score: 0.022 refleja un rendimiento extremadamente bajo en la captura de secuencias de palabras significativas, con muy baja precisión y recall limitado.

3. ROUGE-L Score:

- o **Precision**: 0.038 sugiere que solo el 3.8% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.4 significa que el sistema captura el 40% de la secuencia relevante más larga.
- **F1-Score**: 0.069 refleja un rendimiento muy bajo en la captura de secuencias estructuradas de palabras.

4. **BERTScore**:

- **Precision**: 0.571 indica que el 57.1% de las palabras generadas son semánticamente relevantes.
- Recall: 0.652 sugiere que el sistema captura el 65.2% del contenido semántico relevante.
- F1-Score: 0.609 refleja un rendimiento moderado en términos de correspondencia semántica, lo que indica que el sistema capta algo del significado general del texto, pero con margen para mejorar.

Conclusión: Las métricas ROUGE muestran que el sistema tiene un recall moderado, pero su precisión es extremadamente baja, lo que indica que genera mucho contenido irrelevante, especialmente en las secuencias de palabras. El BERTScore es más favorable, sugiriendo que, aunque el sistema no es preciso en términos literales o estructurales, tiene un rendimiento moderado en términos semánticos. Sin embargo, el sistema necesita mejoras significativas en la precisión y en la captura de secuencias relevantes para generar respuestas más exactas y coherentes.

Respuesta esperada (en las tres implementaciones es la misma respuesta):

Lavar las lentejas y cubrir con agua. Incorporar la guindilla molida y cocinar a fuego bajo hasta lograr tiernizar. Por otro lado realizar

TFM

Alumna: María Carolina Passarello.

una pasta de ajo e incorporarla. Luego la crema y el ghee emulsionándolo. Por último incorporarle La cebolla sudada en ghee junto con ajo picado y el resto de las especias.

Nota: esta preparación debe ser picante y habitualmente se acompañan con chapatis calientes.

Respuesta generada con RAG Básico:

La información proporcionada no incluye una receta específica para preparar el plato DHAL. Sin embargo, se menciona que el DHAL es un ingrediente típico de la cocina hindú y que se consume en combinación con otros alimentos como arroz, chapatis, etc., especialmente durante el almuerzo, que es la comida más fuerte de la jornada.

Para obtener una receta específica del DHAL, sería necesario consultar un manual o recetario de cocina hindú que detalle los ingredientes y el procedimiento de preparación.

Métricas

ROUGE-1 score: Score(precision=0.215909090909090909, recall=0.2714285714285714, fmeasure=0.24050632911392406) ROUGE-2 score: Score(precision=0.022988505747126436, recall=0.028985507246376812, fmeasure=0.02564102564102564) ROUGE-L score: Score(precision=0.13636363636363635, recall=0.17142857142857143, fmeasure=0.15189873417721517) BERTScore - Precision: 0.6570265293121338, Recall: 0.6479616165161133, F1: 0.6524626016616821

Análisis de las Métricas

1. ROUGE-1 Score:

- o **Precision**: 0.216 indica que el 21.6% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.271 muestra que el sistema recupera el 27.1% de las palabras relevantes.
- o **F1-Score**: 0.241 refleja un **rendimiento moderado** con un equilibrio aceptable entre precisión y recall, aunque todavía hay margen de mejora.

2. ROUGE-2 Score:

- o **Precision**: 0.023 indica que solo el 2.3% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 0.029 sugiere que el sistema recupera el 2.9% de los bigrams relevantes.
- F1-Score: 0.026 muestra un rendimiento muy bajo en la captura de secuencias significativas, lo que sugiere que el sistema tiene dificultades en capturar relaciones entre palabras clave.

3. ROUGE-L Score:

- o **Precision**: 0.136 sugiere que el 13.6% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.171 indica que el sistema captura el 17.1% de la secuencia relevante más larga.
- o **F1-Score**: 0.152 refleja un **rendimiento bajo** en términos de mantener la estructura de las secuencias de palabras.

4. BERTScore:

- o **Precision**: 0.657 indica que el 65.7% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.648 sugiere que el sistema captura el 64.8% del contenido semántico relevante.
- F1-Score: 0.652 refleja un rendimiento moderado en términos de correspondencia semántica, con un equilibrio aceptable entre precisión y recall.

Conclusión: Las métricas ROUGE muestran que el sistema tiene un rendimiento moderado en términos de precisión y recall, aunque los resultados en secuencias de palabras y estructura son bastante bajos, lo que sugiere que el sistema tiene dificultades para generar respuestas coherentes y estructuradas. El BERTScore, aunque mejor, indica un rendimiento moderado en términos semánticos, lo que sugiere que el sistema capta parte del significado general, pero todavía necesita mejorar en la precisión y la captura de secuencias relevantes para generar respuestas más exactas y coherentes.

Respuesta generada con RAG con Haystack:

```
Para preparar el plato DHAL, sigue estos pasos:
### Ingredientes:
- Lentejas: 0.250 kg
- Agua: 0.150 l
- Jengibre fresco: 1 cda
- Cúrcuma: 1/2 cda
- Sal: 1 cda
- Ajo: 1 cda
- Cilantro fresco picado: 3 cda
- Ghée: 4 cda
- Cebolla: 1 u
- Granos de comino: 1 cda
- Coriandro: 1/2 cda
- Guindilla en polvo: 1 u
- Crema o yogurt: 0.100 l
### Preparación:
1. **Lavar y cocinar las lentejas:**
   - Lava las lentejas y cúbrelas con agua.
   - Incorpora la guindilla molida y cocina a fuego bajo hasta que
las lentejas estén tiernas.
2. **Preparar la pasta de ajo:**
   - Realiza una pasta de ajo.
3. **Emulsionar la crema y el ghee: **
   - Incorpora la crema y el ghee, emulsionándolos.
4. **Preparar la cebolla y las especias:**
   - Suda la cebolla en ghee junto con ajo picado y el resto de las
especias (comino, coriandro, cúrcuma, jengibre).
5. **Mezclar todos los ingredientes:**
```

TFM

Alumna: María Carolina Passarello.

- Por último, incorpora la cebolla sudada con las especias a las lentejas cocidas.

Nota:

Esta preparación debe ser picante y habitualmente se acompaña con chapatis calientes.

Espero que esta receta te sea útil para preparar el DHAL. ¡Buen provecho!

Métricas:

```
ROUGE-1 score: Score(precision=0.29743589743589743, recall=0.8285714285714286, fmeasure=0.4377358490566038) ROUGE-2 score: Score(precision=0.23195876288659795, recall=0.6521739130434783, fmeasure=0.34220532319391633) ROUGE-L score: Score(precision=0.2717948717948718, recall=0.7571428571428571, fmeasure=0.4) BERTScore - Precision: 0.6478042602539062, Recall: 0.7849833369255066, F1: 0.7098268270492554
```

Análisis de las Métricas.

1. **ROUGE-1 Score**:

- o **Precision**: 0.297 indica que el 29.7% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.829 muestra que el sistema recupera el 82.9% de las palabras relevantes, lo que indica una **alta exhaustividad**.
- F1-Score: 0.438 refleja un desequilibrio entre precisión y recall, lo que sugiere que el sistema recupera muchas palabras relevantes pero también genera bastante contenido irrelevante.

2. ROUGE-2 Score:

- o **Precision**: 0.232 sugiere que el 23.2% de los bigrams generados son correctos en comparación con el texto de referencia.
- **Recall**: 0.652 indica que el sistema recupera el 65.2% de los bigrams relevantes.
- F1-Score: 0.342 refleja un buen recall, pero la precisión sigue siendo baja en la captura de secuencias de palabras significativas.

3. ROUGE-L Score:

- o **Precision**: 0.272 indica que el 27.2% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.757 sugiere que el sistema recupera el 75.7% de la secuencia relevante más larga.
- o **F1-Score**: 0.400 muestra un **desequilibrio similar** al de ROUGE-1, con alta capacidad de recuperación pero baja precisión.

4. **BERTScore**:

- o **Precision**: 0.648 indica que el 64.8% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.785 muestra que el sistema captura el 78.5% del contenido semántico relevante.

 F1-Score: 0.710 refleja un rendimiento moderadamente alto en términos de correspondencia semántica, con un buen balance entre precisión y recall.

Conclusión: Las métricas ROUGE sugieren que el sistema tiene un alto recall (captura gran parte del contenido relevante), pero su precisión es moderada, lo que indica que genera una cantidad significativa de contenido irrelevante. El BERTScore refuerza la idea de que, aunque el sistema no es completamente preciso en términos literales, tiene un buen rendimiento semántico, capturando bien el significado general del texto de referencia. Para mejorar, el sistema debería enfocarse en aumentar la precisión, reduciendo la cantidad de contenido irrelevante generado.

Respuesta generada con RAG con LlamaIndex

El plato DHAL es una mezcla de legumbres y especias. Aunque la palabra "dhal" designa a los guisantes, como las lentejas griegas, los porotos negros, los mung, etc., las preparaciones de dhal suelen ser predominantemente vegetarianas y utilizan granos y legumbres, especias y condimentos como los chiles, la leche de coco, el tamarindo, la canela, hojas de curri, etc. El medio graso básico es el aceite, no el ghée, y se cocina frecuentemente al vapor.

Métricas

```
ROUGE-1 score: Score(precision=0.272727272727272727, recall=0.3, fmeasure=0.28571428571428564)

ROUGE-2 score: Score(precision=0.013157894736842105, recall=0.014492753623188406, fmeasure=0.01379310344827586)

ROUGE-L score: Score(precision=0.12987012987012986, recall=0.14285714285714285, fmeasure=0.13605442176870747)

BERTScore - Precision: 0.6808429956436157, Recall: 0.6575079560279846, F1: 0.6689720153808594
```

Análisis de las Métricas

1. **ROUGE-1 Score**:

- o **Precision**: 0.273 indica que el 27.3% de las palabras generadas son relevantes en comparación con el texto de referencia.
- o **Recall**: 0.300 sugiere que el sistema recupera el 30% de las palabras relevantes.
- F1-Score: 0.286 refleja un equilibrio moderado entre precisión y recall, pero con espacio para mejorar la precisión.

2. ROUGE-2 Score:

- **Precision**: 0.013 indica que solo el 1.3% de los bigrams generados coinciden con los del texto de referencia.
- o **Recall**: 0.014 muestra que el sistema recupera el 1.4% de los bigrams relevantes
- F1-Score: 0.014 refleja un rendimiento extremadamente bajo en la generación de secuencias de palabras significativas, con baja precisión y recall.

3. ROUGE-L Score:

TFM

Alumna: María Carolina Passarello.

- o **Precision**: 0.130 indica que el 13% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.143 sugiere que el sistema recupera el 14.3% de la secuencia relevante más larga.
- **F1-Score**: 0.136 refleja un rendimiento bajo en la captura de secuencias estructuradas, similar a ROUGE-1.

4. BERTScore:

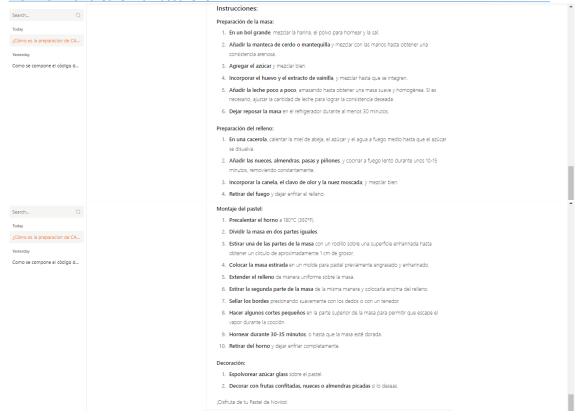
- o **Precision**: 0.681 indica que el 68.1% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.658 muestra que el sistema captura el 65.8% del contenido semántico relevante.
- o **F1-Score**: 0.669 refleja un **rendimiento moderado** en términos de correspondencia semántica, con un buen balance entre precisión y recall.

Conclusión: Las métricas ROUGE muestran que el sistema tiene un rendimiento bajo en términos de precisión y recall, especialmente en la captura de secuencias de palabras significativas. Aunque la precisión en palabras individuales es moderada, el sistema tiene dificultades en las secuencias estructuradas y en capturar relaciones más complejas entre palabras (ROUGE-2). El BERTScore indica que, a nivel semántico, el sistema tiene un rendimiento aceptable, capturando parte del significado general del texto. Sin embargo, el sistema necesita mejorar tanto en precisión literal como en la estructura de las secuencias para generar respuestas más coherentes y exactas.



TFM

Alumna: María Carolina Passarello.



Transcripción

El "Pastel de Novios" es un postre tradicional mexicano que se prepara comúnmente para celebraciones especiales, como bodas. A continuación, te proporciono una receta básica para preparar este delicioso pastel:

Ingredientes:

Para la masa:

- 500 gramos de harina de trigo
- 250 gramos de manteca de cerdo o mantequilla
- 150 gramos de azúcar
- 1 huevo
- 1 cucharadita de polvo para hornear
- 1 cucharadita de extracto de vainilla
- 1 pizca de sal
- 1/2 taza de leche (aproximadamente)

Para el relleno:

- 250 gramos de nuez picada
- 250 gramos de almendra picada

TFM

Alumna: María Carolina Passarello.

- 250 gramos de pasas
- 250 gramos de piñones
- 1 taza de miel de abeja
- 1/2 taza de azúcar
- 1/2 taza de agua
- 1 cucharadita de canela en polvo
- 1/2 cucharadita de clavo de olor en polvo
- 1/2 cucharadita de nuez moscada en polvo

Para decorar:

- Azúcar glass (opcional)
- Frutas confitadas (opcional)
- Nueces o almendras picadas (opcional)

Instrucciones:

Preparación de la masa:

- 1. **En un bol grande**, mezclar la harina, el polvo para hornear y la sal.
- 2. **Añadir la manteca de cerdo o mantequilla** y mezclar con las manos hasta obtener una consistencia arenosa.
- 3. Agregar el azúcar y mezclar bien.
- 4. **Incorporar el huevo y el extracto de vainilla**, y mezclar hasta que se integren.
- 5. **Añadir la leche poco a poco**, amasando hasta obtener una masa suave y homogénea. Si es necesario, ajustar la cantidad de leche para lograr la consistencia deseada.
- 6. **Dejar reposar la masa** en el refrigerador durante al menos 30 minutos.

Preparación del relleno:

- 1. **En una cacerola**, calentar la miel de abeja, el azúcar y el agua a fuego medio hasta que el azúcar se disuelva.
- 2. **Añadir las nueces, almendras, pasas y piñones**, y cocinar a fuego lento durante unos 10-15 minutos, removiendo constantemente.
- 3. Incorporar la canela, el clavo de olor y la nuez moscada, y mezclar bien.
- 4. **Retirar del fuego** y dejar enfriar el relleno.

Montaje del pastel:

- 1. Precalentar el horno a 180°C (350°F).
- 2. Dividir la masa en dos partes iguales.

TFM

Alumna: María Carolina Passarello.

- 3. **Estirar una de las partes de la masa** con un rodillo sobre una superficie enharinada hasta obtener un círculo de aproximadamente 1 cm de grosor.
- Colocar la masa estirada en un molde para pastel previamente engrasado y enharinado.
- 5. Extender el relleno de manera uniforme sobre la masa.
- 6. **Estirar la segunda parte de la masa** de la misma manera y colocarla encima del relleno.
- 7. **Sellar los bordes** presionando suavemente con los dedos o con un tenedor.
- 8. **Hacer algunos cortes pequeños** en la parte superior de la masa para permitir que escape el vapor durante la cocción.
- 9. Hornear durante 30-35 minutos, o hasta que la masa esté dorada.
- 10. Retirar del horno y dejar enfriar completamente.

Decoración:

- 1. Espolvorear azúcar glass sobre el pastel.
- 2. **Decorar con frutas confitadas, nueces o almendras picadas** si lo deseas.

iDisfruta de tu Pastel de Novios!

Métricas sin RAG.

```
ROUGE-1 score: Score(precision=0.056862745098039215, recall=0.30851063829787234, fmeasure=0.09602649006622516) ROUGE-2 score: Score(precision=0.003929273084479371, recall=0.021505376344086023, fmeasure=0.0066445182724252485) ROUGE-L score: Score(precision=0.03725490196078431, recall=0.20212765957446807, fmeasure=0.06291390728476821) BERTScore - Precision: 0.5860195159912109, Recall: 0.6058834195137024, F1: 0.5957859754562378
```

Análisis de las métricas.

Aquí tienes el análisis de las métricas proporcionadas:

1. **ROUGE-1 Score**:

- Precision: 0.057 indica que solo el 5.7% de las palabras generadas son relevantes en comparación con el texto de referencia.
- Recall: 0.309 muestra que el sistema recupera el 30.9% de las palabras relevantes, lo que sugiere un recall moderado pero una precisión muy baja.
- o **F1-Score**: 0.096 refleja un **desequilibrio severo** entre precisión y recall, con una gran cantidad de contenido irrelevante.

2. ROUGE-2 Score:

o **Precision**: 0.004 indica que menos del 1% de los bigrams generados son correctos en comparación con el texto de referencia.

- **Recall**: 0.022 significa que el sistema recupera solo el 2.2% de los bigrams relevantes.
- **F1-Score**: 0.007 muestra un **rendimiento extremadamente bajo** en la captura de secuencias significativas.

3. ROUGE-L Score:

- o **Precision**: 0.037 indica que solo el 3.7% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.202 sugiere que el sistema recupera el 20.2% de la secuencia relevante más larga.
- **F1-Score**: 0.063 refleja un rendimiento muy bajo en términos de captura de secuencias estructuradas, con una precisión extremadamente baja.

4. BERTScore:

- o **Precision**: 0.586 indica que el 58.6% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.606 sugiere que el sistema captura el 60.6% del contenido semántico relevante.
- F1-Score: 0.596 refleja un rendimiento moderado en términos de correspondencia semántica, aunque aún es bastante limitado.

Conclusión: Las métricas ROUGE indican un rendimiento muy bajo, con una precisión extremadamente baja y un recall moderado, lo que sugiere que el sistema genera mucho contenido irrelevante y tiene dificultades para capturar secuencias de palabras importantes. El BERTScore muestra un rendimiento moderado en términos de semántica, lo que indica que, aunque el sistema no logra generar secuencias estructuradas correctas, captura algo del significado general. En resumen, el sistema necesita mejoras sustanciales en precisión y en la estructura de las secuencias para producir respuestas más coherentes y relevantes.

Respuesta esperada (en las tres implementaciones es la misma respuesta):

INGREDIENTES Masa Harina 0.250 Kg Canela c/n Sal c/n Huevo 2 U Manteca 0.050 Kg Oporto 0.040 L Relleno Pollo 0.300 Kg Manteca Kg Cebolla 0.100 Kg Tomate 0.200 Kg Perejil c/n Laurel c/n Pasas de uva 0.070 Kg Laurel c/n Pelones 0.150 Kg Vino blanco 0.200 Kg Ají molido c/n Sal c/n Pimienta c/n Nuez moscada c/n Aceitunas verdes 0.070 kg

TFM

Alumna: María Carolina Passarello.

Huevos 2 u Merengue Suizo Claras 4 u Azúcar 0.200 kg

Respuesta generada con RAG Básico:

```
Los ingredientes para preparar el Pastel de Novios son:
```

```
**Masa:**
- Harina: 0.250 Kg
- Canela: c/n
- Sal: c/n
- Huevo: 2 U
- Manteca: 0.050 Kg
- Oporto: 0.040 L
**Relleno:**
- Pollo: 0.300 Kg
- Manteca: Kg
- Cebolla: 0.100 Kg
- Tomate: 0.200 Kg
- Perejil: c/n
- Laurel: c/n
- Pasas de uva: 0.070 Kg
- Laurel: c/n
- Pelones: 0.150 Kg
- Vino blanco: 0.200 Kg
- Ají molido: c/n
- Sal: c/n
- Pimienta: c/n
- Nuez moscada: c/n
- Aceitunas verdes: 0.070 kg
- Huevos: 2 u
**Merengue Suizo:**
- Claras: 4 u
- Azúcar: 0.200 kg
```

Estos son los ingredientes necesarios para preparar el Pastel de Novios según la receta proporcionada.

Métricas

```
ROUGE-1 score: Score(precision=0.9215686274509803, recall=1.0, fmeasure=0.9591836734693878)

ROUGE-2 score: Score(precision=0.9108910891089109, recall=0.989247311827957, fmeasure=0.9484536082474228)

ROUGE-L score: Score(precision=0.9215686274509803, recall=1.0, fmeasure=0.9591836734693878)

BERTScore - Precision: 0.7833905816078186, Recall: 0.8426860570907593, F1: 0.8119571805000305
```

Análisis de las Métricas

1. ROUGE-1 Score:

- Precision: 0.922 indica que el 92.2% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 1.0 sugiere que el sistema recupera el 100% de las palabras relevantes, lo que refleja una **exhaustividad perfecta**.
- F1-Score: 0.959 muestra un excelente equilibrio entre precisión y recall, lo que indica que el sistema genera respuestas muy relevantes y exhaustivas.

2. ROUGE-2 Score:

- o **Precision**: 0.911 indica que el 91.1% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 0.989 significa que el sistema recupera el 98.9% de los bigrams relevantes.
- F1-Score: 0.948 refleja un rendimiento sobresaliente en la captura de secuencias de palabras significativas.

3. ROUGE-L Score:

- o **Precision**: 0.922 indica que el 92.2% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 1.0 sugiere que el sistema recupera el 100% de la secuencia relevante más larga.
- F1-Score: 0.959 muestra un rendimiento excelente, reflejando una captura casi perfecta de las secuencias más largas de coincidencias.

4. BERTScore:

- o **Precision**: 0.783 indica que el 78.3% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.843 sugiere que el sistema captura el 84.3% del contenido semántico relevante.
- F1-Score: 0.812 refleja un **buen equilibrio** entre precisión y recall, pero no es tan alto como el rendimiento en ROUGE, lo que indica que la correspondencia semántica es buena pero podría mejorar ligeramente en relación con la precisión de las palabras.

Conclusión: Las métricas ROUGE muestran que el sistema tiene un rendimiento excelente, con alta precisión y recall en la generación de palabras y secuencias relevantes. El BERTScore, aunque sigue siendo alto, sugiere que el sistema tiene un buen rendimiento semántico, aunque no tan sobresaliente como su capacidad para capturar palabras exactas y secuencias. En general, el sistema genera respuestas muy precisas, exhaustivas y alineadas tanto en términos literales como en semántica.

Respuesta generada con RAG con Haystack:

Los ingredientes para preparar el Pastel de Novios son los siguientes:

```
### Masa
```

- Harina: 0.250 Kg

- Canela: c/n

- Sal: c/n

- Huevo: 2 U

- Manteca: 0.050 Kg - Oporto: 0.040 L

Relleno

TFM

Alumna: María Carolina Passarello.

```
- Pollo: 0.300 Kg
- Manteca: Kg
- Cebolla: 0.100 Kg
- Tomate: 0.200 Kg
- Perejil: c/n
- Laurel: c/n
- Pasas de uva: 0.070 Kg
- Laurel: c/n
- Pelones: 0.150 Kg
- Vino blanco: 0.200 Kg
- Ají molido: c/n
- Sal: c/n
- Pimienta: c/n
- Nuez moscada: c/n
- Aceitunas verdes: 0.070 kg
- Huevos: 2 u
### Merengue Suizo
- Claras: 4 u
- Azúcar: 0.200 kg
```

Estos son los ingredientes necesarios para preparar el Pastel de Novios según el documento proporcionado.

Métricas:

Análisis de las Métricas.

1. ROUGE-1 Score:

- Precision: 0.783 indica que el 78.3% de las palabras generadas son relevantes en comparación con el texto de referencia.
- o **Recall**: 1.0 sugiere que el sistema recupera el 100% de las palabras relevantes, lo que significa que es **muy exhaustivo**.
- F1-Score: 0.879 refleja un excelente balance entre precisión y recall, con un rendimiento sobresaliente en la generación de palabras relevantes.

2. ROUGE-2 Score:

- o **Precision**: 0.773 muestra que el 77.3% de los bigrams generados son correctos en comparación con el texto de referencia.
- **Recall**: 0.989 indica que el sistema recupera el 98.9% de los bigrams relevantes.
- F1-Score: 0.868 refleja un buen rendimiento en la captura de secuencias de palabras significativas, con un recall excelente y alta precisión.

3. **ROUGE-L Score**:

- o **Precision**: 0.783 indica que el 78.3% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 1.0 sugiere que el sistema recupera el 100% de la secuencia relevante más larga.
- F1-Score: 0.879 refleja un rendimiento muy fuerte en la captura de secuencias largas.

4. BERTScore:

- o **Precision**: 0.762 indica que el 76.2% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.836 sugiere que el sistema captura el 83.6% del contenido semántico relevante.
- F1-Score: 0.797 refleja un buen balance entre precisión y recall, aunque no tan alto como las métricas ROUGE, lo que indica que el sistema capta bien el significado general, pero podría mejorar en la precisión semántica.

Conclusión: Las métricas ROUGE muestran un rendimiento excelente en términos de precisión y recall, lo que indica que el sistema genera respuestas muy relevantes y exhaustivas, tanto a nivel de palabras como de secuencias. El BERTScore sugiere un buen rendimiento semántico, aunque ligeramente menor que el literal, lo que indica que el sistema capta bien el significado general del texto, pero podría mejorar su precisión semántica. En general, el sistema es muy fuerte en la generación de respuestas precisas y exhaustivas.

Respuesta generada con RAG con LLamaIndex

Los ingredientes para preparar el Pastel de Novios son:

```
**Masa:**
- Harina: 0.250 Kg
- Canela: c/n
- Sal: c/n
- Huevo: 2 U
- Manteca: 0.050 Kg
- Oporto: 0.040 L
**Relleno:**
- Pollo: 0.300 Kg
- Manteca: Kg
- Cebolla: 0.100 Kg
- Tomate: 0.200 Kg
- Perejil: c/n
- Laurel: c/n
- Pasas de uva: 0.070 Kg
- Pelones: 0.150 Kg
- Vino blanco: 0.200 Kg
- Ají molido: c/n
- Sal: c/n
- Pimienta: c/n
- Nuez moscada: c/n
- Aceitunas verdes: 0.070 kg
- Huevos: 2 u
```

TFM

Alumna: María Carolina Passarello.

```
**Merengue Suizo:**
- Claras: 4 u
- Azúcar: 0.200 kg
```

Métricas

```
ROUGE-1 score: Score(precision=0.9191919191919192, recall=0.9680851063829787, fmeasure=0.9430051813471503) ROUGE-2 score: Score(precision=0.8979591836734694, recall=0.946236559139785, fmeasure=0.9214659685863874) ROUGE-L score: Score(precision=0.9191919191919192, recall=0.9680851063829787, fmeasure=0.9430051813471503) BERTScore - Precision: 0.781930685043335, Recall: 0.8393353819847107, F1: 0.80961674451828
```

Análisis de las Métricas

1. **ROUGE-1 Score**:

- o **Precision**: 0.919 indica que el 91.9% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.968 sugiere que el sistema recupera el 96.8% de las palabras relevantes, lo que indica una **alta exhaustividad**.
- F1-Score: 0.943 refleja un excelente equilibrio entre precisión y recall, con un rendimiento muy fuerte en la generación de palabras relevantes.

2. ROUGE-2 Score:

- o **Precision**: 0.898 indica que el 89.8% de los bigrams generados son correctos en comparación con el texto de referencia.
- o **Recall**: 0.946 muestra que el sistema recupera el 94.6% de los bigrams relevantes.
- F1-Score: 0.921 refleja un rendimiento sobresaliente en la captura de secuencias de palabras significativas.

3. **ROUGE-L Score**:

- o **Precision**: 0.919 indica que el 91.9% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.968 muestra que el sistema recupera el 96.8% de la secuencia relevante más larga.
- o **F1-Score**: 0.943 muestra un **rendimiento muy fuerte** en la captura de secuencias largas.

4. **BERTScore**:

- **Precision**: 0.782 indica que el 78.2% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.839 sugiere que el sistema captura el 83.9% del contenido semántico relevante.
- F1-Score: 0.810 refleja un buen equilibrio entre precisión y recall en términos de correspondencia semántica, aunque no tan alto como las métricas ROUGE, lo que indica que el sistema capta bien el significado, aunque podría mejorar en la precisión semántica.

Conclusión: Las métricas **ROUGE** muestran que el sistema tiene un **rendimiento excelente** en términos de precisión y recall, generando respuestas muy precisas y exhaustivas tanto a nivel de palabras individuales como de secuencias. El **BERTScore**, aunque bueno, sugiere que el sistema tiene un **buen rendimiento semántico**, pero no

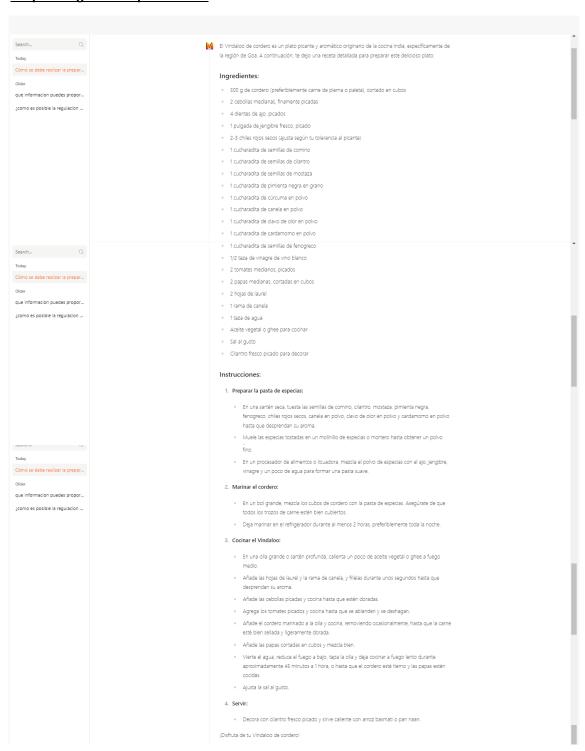
TFM

Alumna: María Carolina Passarello.

tan sobresaliente como su rendimiento en coincidencias literales. En general, el sistema es **muy fuerte** en la generación de respuestas exhaustivas y precisas, con buen rendimiento semántico.

Pregunta 8: ¿Cómo se debe realizar la preparación de Vindalaoo de cordero?

Respuesta generada por LECHAT



Transcripción.

TFM

Alumna: María Carolina Passarello.

El Vindaloo de cordero es un plato picante y aromático originario de la cocina india, específicamente de la región de Goa. A continuación, te dejo una receta detallada para preparar este delicioso plato:

Ingredientes:

- 500 g de cordero (preferiblemente carne de pierna o paleta), cortado en cubos
- 2 cebollas medianas, finamente picadas
- 4 dientes de ajo, picados
- 1 pulgada de jengibre fresco, picado
- 2-3 chiles rojos secos (ajusta según tu tolerancia al picante)
- 1 cucharadita de semillas de comino
- 1 cucharadita de semillas de cilantro
- 1 cucharadita de semillas de mostaza
- 1 cucharadita de pimienta negra en grano
- 1 cucharadita de cúrcuma en polvo
- 1 cucharadita de canela en polvo
- 1 cucharadita de clavo de olor en polvo
- 1 cucharadita de cardamomo en polvo
- 1 cucharadita de semillas de fenogreco
- 1/2 taza de vinagre de vino blanco
- 2 tomates medianos, picados
- 2 papas medianas, cortadas en cubos
- 2 hojas de laurel
- 1 rama de canela
- 1 taza de agua
- Aceite vegetal o ghee para cocinar
- Sal al gusto
- Cilantro fresco picado para decorar

Instrucciones:

1. Preparar la pasta de especias:

 En una sartén seca, tuesta las semillas de comino, cilantro, mostaza, pimienta negra, fenogreco, chiles rojos secos, canela en polvo, clavo de olor en polvo y cardamomo en polvo hasta que desprendan su aroma.

- Muele las especias tostadas en un molinillo de especias o mortero hasta obtener un polvo fino.
- En un procesador de alimentos o licuadora, mezcla el polvo de especias con el ajo, jengibre, vinagre y un poco de agua para formar una pasta suave.

2. Marinar el cordero:

- En un bol grande, mezcla los cubos de cordero con la pasta de especias.
 Asegúrate de que todos los trozos de carne estén bien cubiertos.
- Deja marinar en el refrigerador durante al menos 2 horas, preferiblemente toda la noche.

3. Cocinar el Vindaloo:

- En una olla grande o sartén profunda, calienta un poco de aceite vegetal o ghee a fuego medio.
- Añade las hojas de laurel y la rama de canela, y fríelas durante unos segundos hasta que desprendan su aroma.
- Añade las cebollas picadas y cocina hasta que estén doradas.
- Agrega los tomates picados y cocina hasta que se ablanden y se deshagan.
- Añade el cordero marinado a la olla y cocina, removiendo ocasionalmente, hasta que la carne esté bien sellada y ligeramente dorada.
- Añade las papas cortadas en cubos y mezcla bien.
- Vierte el agua, reduce el fuego a bajo, tapa la olla y deja cocinar a fuego lento durante aproximadamente 45 minutos a 1 hora, o hasta que el cordero esté tierno y las papas estén cocidas.
- Ajusta la sal al gusto.

4. Servir:

 Decora con cilantro fresco picado y sirve caliente con arroz basmati o pan naan.

iDisfruta de tu Vindaloo de cordero!

Métricas sin RAG.

```
ROUGE-1 score: Score(precision=0.1509433962264151, recall=0.6, fmeasure=0.24120603015075376)

ROUGE-2 score: Score(precision=0.04201680672268908, recall=0.16806722689075632, fmeasure=0.06722689075630252)

ROUGE-L score: Score(precision=0.07966457023060797, recall=0.31666666666666666665, fmeasure=0.1273031825795645)

BERTScore - Precision: 0.6457105278968811, Recall: 0.6950012445449829, F1: 0.6694498062133789
```

Análisis de las métricas.

1. **ROUGE-1 Score**:

- o **Precision**: 0.151 indica que solo el 15.1% de las palabras generadas son relevantes en comparación con el texto de referencia.
- o **Recall**: 0.6 sugiere que el sistema recupera el 60% de las palabras relevantes, lo que muestra un **buen recall**, pero con **muy baja precisión**.
- o **F1-Score**: 0.241 refleja un **desequilibrio** significativo entre precisión y recall, donde el sistema es capaz de recuperar muchas palabras relevantes pero genera mucho contenido irrelevante.

2. ROUGE-2 Score:

- **Precision**: 0.042 indica que solo el 4.2% de los bigrams generados son correctos en comparación con el texto de referencia.
- o **Recall**: 0.168 muestra que el sistema recupera el 16.8% de los bigrams relevantes.
- **F1-Score**: 0.067 refleja un **rendimiento bajo** en la generación de secuencias significativas de dos palabras.

3. **ROUGE-L Score**:

- o **Precision**: 0.080 sugiere que el 8% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.317 indica que el sistema recupera el 31.7% de la secuencia relevante más larga.
- o **F1-Score**: 0.127 refleja un **rendimiento bajo** en la captura de secuencias estructuradas, con una **precisión extremadamente baja**.

4. BERTScore:

- **Precision**: 0.646 indica que el 64.6% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.695 muestra que el sistema captura el 69.5% del contenido semántico relevante.
- F1-Score: 0.669 refleja un rendimiento moderado en términos de correspondencia semántica, con un buen balance entre precisión y recall, aunque no es particularmente fuerte.

Conclusión: Las métricas ROUGE muestran que el sistema tiene un recall razonable pero una precisión muy baja, lo que sugiere que genera una cantidad significativa de contenido irrelevante. El rendimiento en secuencias (ROUGE-2 y ROUGE-L) también es bastante bajo, lo que indica que el sistema tiene dificultades para generar respuestas coherentes y estructuradas. El BERTScore sugiere que, aunque el sistema es moderadamente bueno en capturar el significado semántico, su precisión semántica podría mejorar. En resumen, el sistema necesita mejorar tanto en la precisión literal como en la captura de secuencias para generar respuestas más exactas y coherentes.

Respuesta esperada (en las tres implementaciones es la misma respuesta):

En sartén tostar las especias, luego pasar a un mortero y moler Hasta lograr un polvo fino. Luego agregarle la cúrcuma y la guindilla En brunoise. Mojar con unas gotas de limón o vinagre hasta lograr Una pasta. Agregar el jengibre rallado. Reservar. Limpiar la carne de cordero y realizar algunos cortes superficiales. Untar la carne con la pasta y dejar reposar 1

TFM

Alumna: María Carolina Passarello.

hora en la heladera. Sellar la carne en sartén con ghee y ajos enteros. Llevar a horno $180\,^{\circ}\text{C}$.

Tapado con un poco de líquido y cocinar hasta tiernizar.

Nota: para lograr un buen sabor se puede dejar reposar la carne con La pasta de especias en la heladera por 24 hs.

Respuesta generada con RAG Básico:

Para preparar Vindaloo de cordero, sigue estos pasos:

Ingredientes:

- Jengibre fresco rallado (cantidad necesaria)
- Carne de cordero (paletilla) 0.300 kg
- Mix de especias:
 - Guindillas rojas ½ U
 - Cúrcuma (cantidad necesaria)
 - Cardamomo molido (cantidad necesaria)
 - Clavo de olor molido (cantidad necesaria)
 - Canela molida (cantidad necesaria)
 - Pimienta (cantidad necesaria)
 - Coriandro molido (cantidad necesaria)
 - Comino en semillas (cantidad necesaria)
 - Mostaza en granos (cantidad necesaria)
 - Jugo de limón ½ U
 - Ajo 1 Dte
 - Aceite neutro o ghee
 - Agua (cantidad necesaria)

Preparación:

- 1. **Tostar las especias**: En una sartén, tosta las especias (guindillas rojas, cardamomo molido, clavo de olor molido, canela molida, pimienta, coriandro molido, comino en semillas y mostaza en granos).
- 2. **Moler las especias**: Pasa las especias tostadas a un mortero y muélelas hasta lograr un polvo fino.
- 3. **Preparar la pasta de especias**: Agrega la cúrcuma y la guindilla en brunoise al polvo de especias. Mojar con unas gotas de limón o vinagre hasta lograr una pasta. Agregar el jengibre rallado y reservar.
- 4. **Preparar la carne**: Limpia la carne de cordero y realiza algunos cortes superficiales.
- 5. **Marinar la carne**: Unta la carne con la pasta de especias y deja reposar durante 1 hora en la heladera.
- 6. **Sellar la carne**: Sella la carne en una sartén con ghee y ajos enteros.
- 7. **Cocinar en el horno**: Lleva la carne al horno a 180°C, tapada con un poco de líquido y cocina hasta que esté lista.

Siguiendo estos pasos, podrás preparar un delicioso Vindaloo de cordero.

Métricas

ROUGE-1 score: Score(precision=0.3764705882352941, recall=0.8,
fmeasure=0.512)

ROUGE-2 score: Score(precision=0.2677165354330709, recall=0.5714285714285714, fmeasure=0.3646112600536193)

TFM

Alumna: María Carolina Passarello.

```
ROUGE-L score: Score(precision=0.32941176470588235, recall=0.7, fmeasure=0.448)
BERTScore - Precision: 0.6798250675201416, Recall: 0.7882952094078064, F1: 0.7300530672073364
```

Análisis de las Métricas

1. ROUGE-1 Score:

- o **Precision**: 0.376 indica que el 37.6% de las palabras generadas son relevantes en comparación con el texto de referencia.
- o **Recall**: 0.8 muestra que el sistema recupera el 80% de las palabras relevantes, lo que sugiere un **buen recall**.
- F1-Score: 0.512 refleja un equilibrio razonable entre precisión y recall, aunque la precisión podría mejorarse para reducir el contenido irrelevante.

2. ROUGE-2 Score:

- o **Precision**: 0.268 indica que el 26.8% de los bigrams generados coinciden con el texto de referencia.
- o **Recall**: 0.571 sugiere que el sistema recupera el 57.1% de los bigrams relevantes
- o **F1-Score**: 0.365 refleja un **rendimiento moderado** en la captura de secuencias de dos palabras, con margen para mejorar la precisión.

3. ROUGE-L Score:

- o **Precision**: 0.329 sugiere que el 32.9% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.7 indica que el sistema recupera el 70% de la secuencia relevante más larga.
- o **F1-Score**: 0.448 muestra un **rendimiento aceptable**, pero aún podría beneficiarse de una mejor precisión en la estructura de las secuencias.

4. BERTScore:

- o **Precision**: 0.680 muestra que el 68% de las palabras generadas son semánticamente relevantes.
- o **Recall**: 0.788 indica que el sistema captura el 78.8% del contenido semántico relevante.
- **F1-Score**: 0.730 refleja un **buen equilibrio** entre precisión y recall en términos de correspondencia semántica.

Conclusión: Las métricas ROUGE indican que el sistema tiene un buen recall, pero su precisión es moderada, lo que sugiere que genera una cantidad significativa de contenido irrelevante. El BERTScore refuerza la idea de que, aunque el sistema es capaz de capturar el significado general de manera razonablemente buena, mejorar la precisión podría reducir el contenido irrelevante.

Respuesta generada con RAG con Haystack:

```
Para preparar Vindaloo de cordero, sigue estos pasos:
### Ingredientes:
- Jengibre fresco rallado (cantidad necesaria)
- Carne de cordero (paletilla) 0.300 kg
- Mix de especias:
- Guindillas rojas ½ unidad
```

TFM

Alumna: María Carolina Passarello.

- Cúrcuma (cantidad necesaria)
- Cardamomo molido (cantidad necesaria)
- Clavo de olor molido (cantidad necesaria)
- Canela molida (cantidad necesaria)
- Pimienta (cantidad necesaria)
- Coriandro molido (cantidad necesaria)
- Comino en semillas (cantidad necesaria)
- Mostaza en granos (cantidad necesaria)
- Jugo de limón ½ unidad
- Ajo 1 diente
- Aceite neutro o ghee
- Agua (cantidad necesaria)

Preparación:

- 1. **Tostar las especias**: En una sartén, tostar las especias (cardamomo, clavo de olor, canela, pimienta, coriandro, comino y mostaza) hasta que desprendan su aroma.
- 2. **Moler las especias**: Pasar las especias tostadas a un mortero y moler hasta lograr un polvo fino.
- 3. **Preparar la pasta de especias**: Agregar la cúrcuma y la guindilla en brunoise al polvo de especias. Mojar con unas gotas de limón o vinagre hasta lograr una pasta. Agregar el jengibre rallado y mezclar bien. Reservar.
- 4. **Preparar la carne**: Limpiar la carne de cordero y realizar algunos cortes superficiales. Untar la carne con la pasta de especias y dejar reposar en la heladera por 1 hora (o hasta 24 horas para un mejor sabor).
- 5. **Sellar la carne**: En una sartén con ghee, sellar la carne junto con ajos enteros.
- 6. **Cocinar en el horno**: Llevar la carne al horno a 180°C, tapada con un poco de líquido, y cocinar hasta que esté tierna.

Nota:

Para lograr un mejor sabor, se puede dejar reposar la carne con la pasta de especias en la heladera por 24 horas.

Este proceso asegura que la carne de cordero absorba bien los sabores de las especias y quede tierna y deliciosa.

Métricas:

ROUGE-1 score: Score(precision=0.392361111111111111, recall=0.9416666666666667, fmeasure=0.5539215686274509) ROUGE-2 score: Score(precision=0.3170731707317073, recall=0.7647058823529411, fmeasure=0.4482758620689655) ROUGE-L score: Score(precision=0.3784722222222222, recall=0.908333333333333333, fmeasure=0.5343137254901961) BERTScore - Precision: 0.7010908722877502, Recall: 0.8044819235801697, F1: 0.7492363452911377

Análisis de las Métricas.

1. ROUGE-1 Score:

- Precision: 0.392 indica que el 39.2% de las palabras generadas son relevantes en comparación con el texto de referencia.
- o **Recall**: 0.942 sugiere que el sistema recupera el 94.2% de las palabras relevantes, lo que indica una **alta exhaustividad**.

 F1-Score: 0.554 refleja un desequilibrio entre precisión y recall, donde el sistema captura muchas palabras relevantes pero también genera contenido irrelevante.

2. ROUGE-2 Score:

- o **Precision**: 0.317 muestra que el 31.7% de los bigrams generados son correctos en comparación con el texto de referencia.
- **Recall**: 0.765 indica que el sistema recupera el 76.5% de los bigrams relevantes.
- F1-Score: 0.448 refleja un buen rendimiento en la captura de secuencias de palabras significativas, aunque la precisión podría mejorarse.

3. ROUGE-L Score:

- o **Precision**: 0.378 sugiere que el 37.8% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- Recall: 0.908 indica que el sistema recupera el 90.8% de la secuencia relevante más larga.
- **F1-Score**: 0.534 muestra un **buen balance**, pero con espacio para mejorar la precisión en las secuencias estructuradas.

4. BERTScore:

- o **Precision**: 0.701 indica que el 70.1% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.804 sugiere que el sistema captura el 80.4% del contenido semántico relevante.
- **F1-Score**: 0.749 refleja un **buen equilibrio** entre precisión y recall en términos de correspondencia semántica.

Conclusión: Las métricas ROUGE muestran que el sistema tiene un alto recall, capturando la mayor parte del contenido relevante, pero su precisión es moderada, lo que indica que genera contenido irrelevante. El BERTScore refuerza la idea de que el sistema tiene un buen rendimiento semántico, pero podría mejorar la precisión para generar respuestas más exactas y menos redundantes. En general, el sistema es bueno en términos de exhaustividad, pero hay margen para mejorar la precisión en la generación de secuencias y significado semántico.

Respuesta generada con RAG con LLamaIndex

Para preparar Vindaloo de cordero, primero se deben tostar las especias en una sartén y luego molerlas en un mortero hasta obtener un polvo fino. A continuación, se agrega cúrcuma y guindilla en brunoise, y se moja con unas gotas de limón o vinagre hasta lograr una pasta. Luego, se añade jengibre rallado y se reserva. La carne de cordero se limpia y se realizan algunos cortes superficiales. Se unta la carne con la pasta de especias y se deja reposar en la heladera durante una hora. Después, se sella la carne en una sartén con ghee y ajos enteros, y se lleva al horno a 180°C, tapada con un poco de líquido, hasta que esté tierna. Para un mejor sabor, se puede dejar reposar la carne con la pasta de especias en la heladera durante 24 horas.

Métricas

TFM

Alumna: María Carolina Passarello.

Análisis de las Métricas

1. ROUGE-1 Score:

- o **Precision**: 0.646 indica que el 64.6% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.792 sugiere que el sistema recupera el 79.2% de las palabras relevantes, lo que indica una **alta capacidad de recuperación**.
- **F1-Score**: 0.712 refleja un **buen equilibrio** entre precisión y recall, con un rendimiento sólido en la generación de palabras relevantes.

2. ROUGE-2 Score:

- o **Precision**: 0.418 indica que el 41.8% de los bigrams generados coinciden con el texto de referencia.
- **Recall**: 0.513 muestra que el sistema recupera el 51.3% de los bigrams relevantes.
- F1-Score: 0.460 refleja un rendimiento moderado en la captura de secuencias de palabras, donde hay un buen recall pero la precisión podría mejorarse.

3. ROUGE-L Score:

- o **Precision**: 0.585 sugiere que el 58.5% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.717 indica que el sistema recupera el 71.7% de la secuencia relevante más larga.
- o **F1-Score**: 0.644 muestra un **buen balance** en la captura de secuencias estructuradas, aunque aún hay espacio para mejorar la precisión.

4. BERTScore:

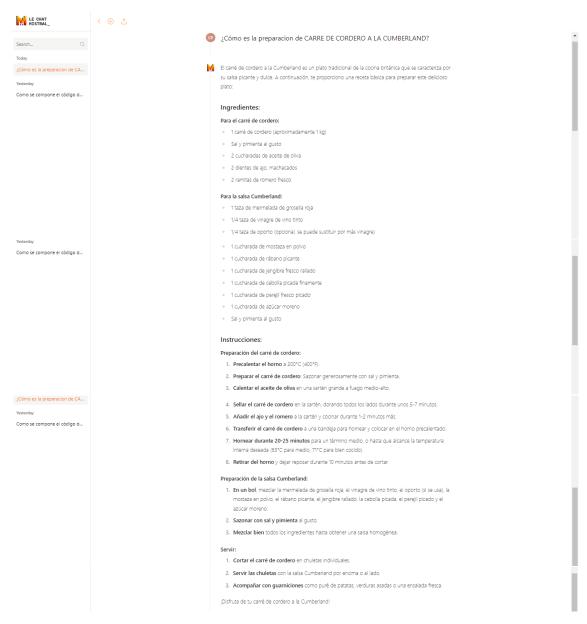
- **Precision**: 0.833 indica que el 83.3% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.846 muestra que el sistema captura el 84.6% del contenido semántico relevante.
- **F1-Score**: 0.839 refleja un **excelente equilibrio** entre precisión y recall en términos de correspondencia semántica.

Conclusión: Las métricas ROUGE sugieren que el sistema tiene un buen rendimiento en términos de captura de palabras y secuencias relevantes, con un alto recall y una precisión moderada. El BERTScore indica que el sistema tiene un rendimiento muy fuerte en términos de correspondencia semántica, lo que sugiere que las respuestas generadas son coherentes y bien alineadas con el significado general del texto. En general, el sistema es sólido tanto en términos literales como semánticos, aunque podría mejorar la precisión en las secuencias de palabras.

TFM

Alumna: María Carolina Passarello.

Respuesta generada por LECHAT



Transcripción:

El carré de cordero a la Cumberland es un plato tradicional de la cocina británica que se caracteriza por su salsa picante y dulce. A continuación, te proporciono una receta básica para preparar este delicioso plato:

Ingredientes:

Para el carré de cordero:

- 1 carré de cordero (aproximadamente 1 kg)
- Sal y pimienta al gusto
- 2 cucharadas de aceite de oliva
- 2 dientes de ajo, machacados

TFM

Alumna: María Carolina Passarello.

• 2 ramitas de romero fresco

Para la salsa Cumberland:

- 1 taza de mermelada de grosella roja
- 1/4 taza de vinagre de vino tinto
- 1/4 taza de oporto (opcional, se puede sustituir por más vinagre)
- 1 cucharada de mostaza en polvo
- 1 cucharada de rábano picante
- 1 cucharada de jengibre fresco rallado
- 1 cucharada de cebolla picada finamente
- 1 cucharada de perejil fresco picado
- 1 cucharada de azúcar moreno
- Sal y pimienta al gusto

Instrucciones:

Preparación del carré de cordero:

- 1. Precalentar el horno a 200°C (400°F).
- 2. **Preparar el carré de cordero**: Sazonar generosamente con sal y pimienta.
- 3. Calentar el aceite de oliva en una sartén grande a fuego medio-alto.
- 4. **Sellar el carré de cordero** en la sartén, dorando todos los lados durante unos 5-7 minutos.
- 5. **Añadir el ajo y el romero** a la sartén y cocinar durante 1-2 minutos más.
- 6. **Transferir el carré de cordero** a una bandeja para hornear y colocar en el horno precalentado.
- 7. **Hornear durante 20-25 minutos** para un término medio, o hasta que alcance la temperatura interna deseada (63°C para medio, 71°C para bien cocido).
- 8. **Retirar del horno** y dejar reposar durante 10 minutos antes de cortar.

Preparación de la salsa Cumberland:

- 1. **En un bol**, mezclar la mermelada de grosella roja, el vinagre de vino tinto, el oporto (si se usa), la mostaza en polvo, el rábano picante, el jengibre rallado, la cebolla picada, el perejil picado y el azúcar moreno.
- 2. Sazonar con sal y pimienta al gusto.
- 3. Mezclar bien todos los ingredientes hasta obtener una salsa homogénea.

Servir:

1. Cortar el carré de cordero en chuletas individuales.

TFM

Alumna: María Carolina Passarello.

- 2. Servir las chuletas con la salsa Cumberland por encima o al lado.
- 3. **Acompañar con guarniciones** como puré de patatas, verduras asadas o una ensalada fresca.

¡Disfruta de tu carré de cordero a la Cumberland!

Métricas sin RAG.

```
ROUGE-1 score: Score(precision=0.14962593516209477, recall=0.6896551724137931, fmeasure=0.24590163934426232) ROUGE-2 score: Score(precision=0.0375, recall=0.1744186046511628, fmeasure=0.0617283950617284) ROUGE-L score: Score(precision=0.0798004987531172, recall=0.367816091954023, fmeasure=0.13114754098360654) BERTScore - Precision: 0.6483492255210876, Recall: 0.710476279258728, F1: 0.6779925227165222
```

Análisis de las métricas.

1. **ROUGE-1 Score**:

- o **Precision**: 0.150 indica que solo el 15% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.690 sugiere que el sistema recupera el 69% de las palabras relevantes, lo que indica un **buen recall**, pero con **baja precisión**.
- o **F1-Score**: 0.246 refleja un **desequilibrio** significativo entre precisión y recall, lo que sugiere que el sistema genera mucho contenido irrelevante, aunque recupera una cantidad significativa de palabras relevantes.

2. **ROUGE-2 Score**:

- o **Precision**: 0.038 indica que solo el 3.8% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 0.174 muestra que el sistema recupera el 17.4% de los bigrams relevantes.
- F1-Score: 0.062 refleja un rendimiento bajo en la generación de secuencias de dos palabras.

3. ROUGE-L Score:

- o **Precision**: 0.080 indica que solo el 8% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.368 sugiere que el sistema recupera el 36.8% de la secuencia relevante más larga.
- o **F1-Score**: 0.131 refleja un rendimiento **bajo** en la captura de secuencias estructuradas, con una precisión muy baja.

4. **BERTScore**:

- **Precision**: 0.648 muestra que el 64.8% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.710 sugiere que el sistema captura el 71% del contenido semántico relevante.
- F1-Score: 0.678 refleja un rendimiento moderado en términos de correspondencia semántica, con un buen balance entre precisión y recall.

TFM

Alumna: María Carolina Passarello.

Conclusión: Las métricas ROUGE indican que el sistema tiene un buen recall pero una precisión muy baja, lo que sugiere que genera mucho contenido irrelevante. El rendimiento en secuencias (ROUGE-2 y ROUGE-L) es especialmente bajo, lo que indica que el sistema tiene dificultades en capturar relaciones entre palabras y generar respuestas estructuradas. El BERTScore muestra un rendimiento moderado en términos de semántica, lo que indica que, aunque el sistema capta parte del significado general, necesita mejoras en precisión y estructura para generar respuestas más coherentes y relevantes.

Respuesta esperada (en las tres implementaciones es la misma respuesta):

Deshuesar el carré, calentar una sartén con aceite neutro, colocar Los ajos encamisados y sellar la carne hasta dorar. Terminar la cocción En horno a 200 $^{\circ}$ C por 5 minutos.

Blanquear las cascaras de limón y naranjas. Fundir el dulce de grosellas con el oporto, las julianas, y el jugo de naranja. Dejar enfriar. La mostaza inglesa, la sal y la pimienta agregarlos en frío. Pelar y tornear las papas a la inglesa. Cocinarlas en agua y sal. Servir Con aceite de oliva.

Respuesta generada con RAG Básico:

La preparación de CARRE DE CORDERO A LA CUMBERLAND es la siguiente:

- **INGREDIENTES:**
- Carre de cordero u 1
- Sal c/n
- Pimienta c/n
- Aceite c/n
- Ajo u 2
- Salsa Cumberland
 - Dulce de grosellas 0.100 kg
 - Oporto 1 0.050
 - Juliana de naranja u 1
 - Juliana de limón u 1
 - Jugo de naranja u 1
 - Mostaza inglesa 0.020 kg
 - Sal y pimienta c/n
- Guarnición
 - Papas kg 0.300
 - Sal c/n
 - Pimienta c/n
 - Aceite de oliva c/n

PREPARACIÓN:

- 1. Deshuesar el carré.
- 2. Calentar una sartén con aceite neutro, colocar los ajos encamisados y sellar la carne hasta dorar.
- 3. Terminar la cocción en horno a 200°C por 5 minutos.
- 4. Blanquear las cascaras de limón y naranjas.
- 5. Fundir el dulce de grosellas con el oporto, las julianas, y el jugo de naranja. Dejar enfriar.
- 6. La mostaza inglesa, la sal y la pimienta agregarlos en frío.
- 7. Pelar y tornear las papas a la inglesa.
- 8. Cocinarlas en agua y sal.
- 9. Servir con aceite de oliva.

TFM

Alumna: María Carolina Passarello.

Métricas

```
ROUGE-1 score: Score(precision=0.47282608695652173, recall=1.0, fmeasure=0.6420664206642066)

ROUGE-2 score: Score(precision=0.4262295081967213, recall=0.9069767441860465, fmeasure=0.5799256505576208)

ROUGE-L score: Score(precision=0.47282608695652173, recall=1.0, fmeasure=0.6420664206642066)

BERTScore - Precision: 0.7092757821083069, Recall: 0.8641182780265808, F1: 0.7790777683258057
```

Análisis de las Métricas

1. **ROUGE-1 Score**:

- o **Precision**: 0.473 indica que el 47.3% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 1.0 muestra que el sistema recupera el 100% de las palabras relevantes, lo que indica una **exhaustividad perfecta**.
- o **F1-Score**: 0.642 refleja un **desequilibrio** entre precisión y recall, lo que sugiere que el sistema genera todas las palabras relevantes, pero también incluye una cantidad considerable de contenido irrelevante.

2. ROUGE-2 Score:

- o **Precision**: 0.426 indica que el 42.6% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 0.907 muestra que el sistema recupera el 90.7% de los bigrams relevantes.
- o **F1-Score**: 0.580 refleja un **buen recall**, pero la precisión podría mejorarse para reducir el contenido irrelevante en secuencias.

3. ROUGE-L Score:

- o **Precision**: 0.473 indica que el 47.3% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 1.0 sugiere que el sistema recupera el 100% de la secuencia relevante más larga.
- o **F1-Score**: 0.642 refleja un rendimiento similar al de ROUGE-1, destacando la **exhaustividad** a costa de precisión.

4. BERTScore:

- **Precision**: 0.709 muestra que el 70.9% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.864 indica que el sistema captura el 86.4% del contenido semántico relevante.
- F1-Score: 0.779 refleja un buen balance entre precisión y recall en términos de correspondencia semántica, aunque la precisión podría mejorar.

Conclusión: Las métricas ROUGE muestran que el sistema tiene un recall excelente, capturando la totalidad del contenido relevante, pero su precisión es moderada, lo que indica que genera mucho contenido irrelevante. El BERTScore sugiere que el sistema tiene un buen rendimiento semántico, con un buen equilibrio entre precisión y recall, aunque aún hay espacio para mejorar la precisión para reducir el contenido innecesario. En resumen, el sistema es muy exhaustivo pero debe mejorar en la precisión para generar respuestas más concisas y relevantes.

Respuesta generada con RAG con Haystack:

La preparación del Carré de Cordero a la Cumberland se realiza de la siguiente manera:

Ingredientes:

- Carré de cordero: 1 unidad
- Sal: cantidad necesaria
- Pimienta: cantidad necesaria
- Aceite: cantidad necesaria
- Ajo: 2 unidades
- Salsa Cumberland:
 - Dulce de grosellas: 0.100 kg
 - Oporto: 0.050 litros
 - Juliana de naranja: 1 unidad
 - Juliana de limón: 1 unidad
 - Jugo de naranja: 1 unidad
 - Mostaza inglesa: 0.020 kg
 - Sal y pimienta: cantidad necesaria
- Guarnición:
 - Papas: 0.300 kg
 - Sal: cantidad necesaria
 - Pimienta: cantidad necesaria
 - Aceite de oliva: cantidad necesaria

Preparación:

- 1. **Deshuesar el carré**: Comienza deshuesando el carré de cordero.
- 2. **Sellar la carne**: Calienta una sartén con aceite neutro y coloca los ajos encamisados. Sella la carne hasta que esté dorada.
- 3. **Cocción en horno**: Termina la cocción en el horno a $200\,^{\circ}\text{C}$ durante 5 minutos.
- 4. **Preparar la salsa Cumberland**:
 - Blanquear las cáscaras de limón y naranja.
- Fundir el dulce de grosellas con el oporto, las julianas de naranja y limón, y el jugo de naranja. Dejar enfriar.
 - Agregar la mostaza inglesa, la sal y la pimienta en frío.
- 5. **Preparar la quarnición**:
 - Pelar y tornear las papas a la inglesa.
 - Cocinarlas en agua y sal.
 - Servir con aceite de oliva.

Notas adicionales:

- La carne de cordero combina muy bien con hierbas y especias, frutos desecados y vegetales en general.
- El método de cocción que mejor se aplica sobre esta carne es asar, o dependiendo de que se trate de un animal adulto, en ese caso guisar será la mejor preparación para esta carne.

Esta receta proporciona una guía completa para preparar un delicioso Carré de Cordero a la Cumberland, acompañado de una salsa Cumberland y una guarnición de papas.

Métricas:

TFM

Alumna: María Carolina Passarello.

```
ROUGE-1 score: Score(precision=0.2684563758389262, recall=0.9195402298850575, fmeasure=0.4155844155844156) ROUGE-2 score: Score(precision=0.2255892255892256, recall=0.7790697674418605, fmeasure=0.34986945169712796) ROUGE-L score: Score(precision=0.26174496644295303, recall=0.896551724137931, fmeasure=0.4051948051948052) BERTScore - Precision: 0.6552736759185791, Recall: 0.7882920503616333, F1: 0.7156543135643005
```

Análisis de las Métricas.

1. ROUGE-1 Score:

- o **Precision**: 0.268 indica que el 26.8% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.920 muestra que el sistema recupera el 92% de las palabras relevantes, lo que indica una **alta exhaustividad**.
- F1-Score: 0.416 refleja un desequilibrio entre precisión y recall, lo que sugiere que el sistema captura muchas palabras relevantes pero también genera bastante contenido irrelevante.

2. ROUGE-2 Score:

- o **Precision**: 0.226 indica que el 22.6% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 0.779 muestra que el sistema recupera el 77.9% de los bigrams relevantes.
- **F1-Score**: 0.350 refleja un **buen recall** en la captura de secuencias de palabras, aunque la **precisión sigue siendo baja**.

3. ROUGE-L Score:

- o **Precision**: 0.262 indica que el 26.2% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.897 sugiere que el sistema recupera el 89.7% de la secuencia relevante más larga.
- **F1-Score**: 0.405 refleja un rendimiento similar al de ROUGE-1, destacando un **alto recall** a costa de una **precisión limitada**.

4. BERTScore:

- **Precision**: 0.655 muestra que el 65.5% de las palabras generadas son semánticamente relevantes.
- Recall: 0.788 indica que el sistema captura el 78.8% del contenido semántico relevante.
- F1-Score: 0.716 refleja un buen equilibrio entre precisión y recall en términos de correspondencia semántica, aunque la precisión podría mejorarse.

Conclusión: Las métricas ROUGE indican que el sistema tiene un alto recall, recuperando gran parte del contenido relevante, pero su precisión es baja, lo que indica que genera contenido irrelevante. El BERTScore sugiere que el sistema tiene un rendimiento semántico sólido, aunque la precisión semántica también podría mejorarse. En resumen, el sistema es muy exhaustivo, pero necesita mejorar en la precisión tanto en términos literales como semánticos para generar respuestas más relevantes y concisas.

Respuesta generada con RAG con LLamaIndex

Para preparar el Carré de Cordero a la Cumberland, primero se deshuesa el carré. Luego, se calienta una sartén con aceite neutro y se colocan los ajos encamisados para sellar la carne hasta dorarla. La cocción se termina en el horno a 200°C durante 5 minutos.

Para la salsa Cumberland, se blanquean las cáscaras de limón y naranja. Se funde el dulce de grosellas con el oporto, las julianas de naranja y limón, y el jugo de naranja. Se deja enfriar y se agregan la mostaza inglesa, la sal y la pimienta en frío.

Para la guarnición, se pelan y tornean las papas a la inglesa, se cocinan en agua y sal, y se sirven con aceite de oliva.

Métricas

ROUGE-1 score: Score(precision=0.5669291338582677, recall=0.8275862068965517, fmeasure=0.6728971962616822) ROUGE-2 score: Score(precision=0.4126984126984127, recall=0.6046511627906976, fmeasure=0.49056603773584895) ROUGE-L score: Score(precision=0.5590551181102362, recall=0.8160919540229885, fmeasure=0.6635514018691588) BERTScore - Precision: 0.8124735355377197, Recall: 0.8410323858261108, F1: 0.8265063166618347

Análisis de las Métricas

1. ROUGE-1 Score:

- o **Precision**: 0.567 indica que el 56.7% de las palabras generadas son relevantes en comparación con el texto de referencia.
- **Recall**: 0.828 muestra que el sistema recupera el 82.8% de las palabras relevantes, lo que refleja una **alta exhaustividad**.
- F1-Score: 0.673 muestra un buen equilibrio entre precisión y recall, lo que indica que el sistema es capaz de capturar una gran cantidad de contenido relevante con una precisión razonable.

2. ROUGE-2 Score:

- Precision: 0.413 indica que el 41.3% de los bigrams generados son correctos en comparación con el texto de referencia.
- **Recall**: 0.605 significa que el sistema recupera el 60.5% de los bigrams relevantes.
- F1-Score: 0.491 refleja un rendimiento moderado en la captura de secuencias de palabras, con una buena capacidad de recuperación, aunque la precisión podría mejorarse.

3. ROUGE-L Score:

- o **Precision**: 0.559 sugiere que el 55.9% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.816 indica que el sistema recupera el 81.6% de la secuencia relevante más larga.
- F1-Score: 0.664 refleja un buen rendimiento en términos de secuencias, con una buena recuperación, aunque con espacio para mejorar en la precisión.

4. BERTScore:

TFM

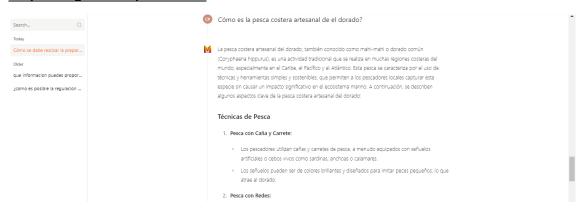
Alumna: María Carolina Passarello.

- o **Precision**: 0.812 indica que el 81.2% de las palabras generadas son semánticamente relevantes.
- Recall: 0.841 sugiere que el sistema captura el 84.1% del contenido semántico relevante.
- o **F1-Score**: 0.827 refleja un **muy buen equilibrio** entre precisión y recall en términos de correspondencia semántica.

Conclusión: Las métricas ROUGE indican que el sistema tiene un alto recall y una precisión moderada, lo que sugiere que es capaz de capturar gran parte del contenido relevante, aunque genera algo de contenido irrelevante. El BERTScore muestra un rendimiento muy fuerte en términos de correspondencia semántica, lo que indica que las respuestas generadas son coherentes y bien alineadas con el significado del texto de referencia. En general, el sistema es sólido tanto en términos literales como semánticos, aunque mejorar la precisión podría hacer que las respuestas sean más concisas y exactas.

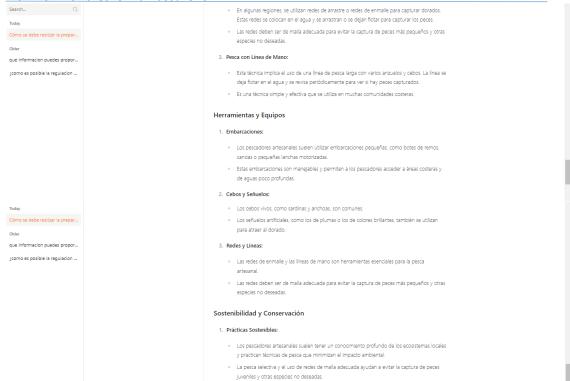
Pregunta 10: ¿Cómo es la pesca costera artesanal de el dorado?

Respuesta generada por LECHAT



TFM

Alumna: María Carolina Passarello.



Transcripción

La pesca costera artesanal del dorado, también conocido como mahi-mahi o dorado común (Coryphaena hippurus), es una actividad tradicional que se realiza en muchas regiones costeras del mundo, especialmente en el Caribe, el Pacífico y el Atlántico. Esta pesca se caracteriza por el uso de técnicas y herramientas simples y sostenibles, que permiten a los pescadores locales capturar esta especie sin causar un impacto significativo en el ecosistema marino. A continuación, se describen algunos aspectos clave de la pesca costera artesanal del dorado:

Técnicas de Pesca

1. Pesca con Caña y Carrete:

- Los pescadores utilizan cañas y carretes de pesca, a menudo equipados con señuelos artificiales o cebos vivos como sardinas, anchoas o calamares.
- Los señuelos pueden ser de colores brillantes y diseñados para imitar peces pequeños, lo que atrae al dorado.

2. Pesca con Redes:

- En algunas regiones, se utilizan redes de arrastre o redes de enmalle para capturar dorados. Estas redes se colocan en el agua y se arrastran o se dejan flotar para capturar los peces.
- Las redes deben ser de malla adecuada para evitar la captura de peces más pequeños y otras especies no deseadas.

3. Pesca con Línea de Mano:

- Esta técnica implica el uso de una línea de pesca larga con varios anzuelos y cebos. La línea se deja flotar en el agua y se revisa periódicamente para ver si hay peces capturados.
- Es una técnica simple y efectiva que se utiliza en muchas comunidades costeras.

Herramientas y Equipos

1. Embarcaciones:

- Los pescadores artesanales suelen utilizar embarcaciones pequeñas, como botes de remos, canoas o pequeñas lanchas motorizadas.
- Estas embarcaciones son manejables y permiten a los pescadores acceder a áreas costeras y de aguas poco profundas.

2. Cebos y Señuelos:

- Los cebos vivos, como sardinas y anchoas, son comunes.
- Los señuelos artificiales, como los de plumas o los de colores brillantes, también se utilizan para atraer al dorado.

3. Redes y Líneas:

- Las redes de enmalle y las líneas de mano son herramientas esenciales para la pesca artesanal.
- Las redes deben ser de malla adecuada para evitar la captura de peces más pequeños y otras especies no deseadas.

Sostenibilidad y Conservación

1. Prácticas Sostenibles:

- Los pescadores artesanales suelen tener un conocimiento profundo de los ecosistemas locales y practican técnicas de pesca que minimizan el impacto ambiental.
- La pesca selectiva y el uso de redes de malla adecuada ayudan a evitar la captura de peces juveniles y otras especies no deseadas.

2. Regulaciones y Normativas:

- En muchas regiones, existen regulaciones que establecen temporadas de pesca, tamaños mínimos de captura y áreas de pesca protegidas.
- Estas regulaciones ayudan a mantener las poblaciones de dorado y otros peces en niveles sostenibles.

3. Comunidades Locales:

• La pesca artesanal es una fuente importante de sustento y empleo para muchas comunidades costeras.

TFM

Alumna: María Carolina Passarello.

• Las prácticas sostenibles y la gestión adecuada de los recursos pesqueros son esenciales para el bienestar de estas comunidades.

Beneficios y Desafíos

1. Beneficios:

- La pesca artesanal proporciona una fuente de alimento fresca y nutritiva.
- Soporta la economía local y proporciona empleo a los pescadores.
- Fomenta la conservación de técnicas tradicionales y el conocimiento ecológico.

2. Desafíos:

- La competencia con la pesca comercial a gran escala.
- La presión sobre los recursos pesqueros debido a la sobrepesca y la contaminación.
- La necesidad de adaptarse a los cambios climáticos y a las fluctuaciones en las poblaciones de peces.

La pesca costera artesanal del dorado es una actividad que combina tradición, sostenibilidad y conocimiento local. Es crucial apoyar y promover estas prácticas para asegurar la conservación de los recursos marinos y el bienestar de las comunidades costeras.

Métricas sin RAG.

```
ROUGE-1 score: Score(precision=0.29147286821705426, recall=0.49473684210526314, fmeasure=0.366829268292683) ROUGE-2 score: Score(precision=0.05124223602484472, recall=0.0870712401055409, fmeasure=0.06451612903225806) ROUGE-L score: Score(precision=0.12403100775193798, recall=0.21052631578947367, fmeasure=0.1560975609750973) BERTScore - Precision: 0.6810516715049744, Recall: 0.689364492893219, F1: 0.6851828694343567
```

Análisis de las métricas.

1. ROUGE-1 Score:

- o **Precision**: 0.291 indica que el 29.1% de las palabras generadas son relevantes en comparación con el texto de referencia.
- Recall: 0.495 sugiere que el sistema recupera el 49.5% de las palabras relevantes, lo que refleja un recall moderado pero una precisión baja.
- **F1-Score**: 0.367 muestra un rendimiento **moderado** en la captura de palabras relevantes, con un equilibrio limitado entre precisión y recall.

2. ROUGE-2 Score:

- **Precision**: 0.051 indica que solo el 5.1% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 0.087 muestra que el sistema recupera el 8.7% de los bigrams relevantes.

o **F1-Score**: 0.065 refleja un **rendimiento bajo** en la captura de secuencias de palabras significativas, tanto en términos de precisión como de recall.

3. ROUGE-L Score:

- o **Precision**: 0.124 sugiere que el 12.4% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- Recall: 0.211 indica que el sistema recupera el 21.1% de la secuencia relevante más larga.
- F1-Score: 0.156 refleja un rendimiento bajo en la captura de secuencias estructuradas, con una precisión muy baja.

4. **BERTScore**:

- **Precision**: 0.681 muestra que el 68.1% de las palabras generadas son semánticamente relevantes.
- Recall: 0.689 indica que el sistema captura el 68.9% del contenido semántico relevante.
- F1-Score: 0.685 refleja un rendimiento moderado en términos de correspondencia semántica, con un equilibrio aceptable entre precisión y recall.

Conclusión: Las métricas ROUGE muestran que el sistema tiene un recall moderado pero una precisión muy baja, lo que sugiere que genera una cantidad significativa de contenido irrelevante. El rendimiento en secuencias (ROUGE-2 y ROUGE-L) es especialmente bajo, lo que indica que el sistema tiene dificultades en capturar relaciones entre palabras y generar respuestas estructuradas. El BERTScore, aunque moderado, muestra que el sistema capta algo del significado general, pero hay espacio para mejorar tanto la precisión como la estructura de las secuencias para generar respuestas más coherentes y relevantes.

Respuesta esperada (en las tres implementaciones es la misma respuesta):

Es uno de los principales objetos de pesca deportiva en la Argentina, junto con las distintas

especies de surubí, y una de las presas más exigentes de la pesca de agua dulce en el mundo ya

que salta muy alto y antes de ser atrapado, ofrece una lucha formidable en donde se conjugan

fuertes sacudidas y saltos. Se caracteriza además por ser un buen nadador, prefiere aquas de

fuertes correntadas, donde encuentra buenas cantidades de oxígeno y mejores posibilidades de

cazar y encontrar alimento. Es un depredador nato y agresivo. Supera el metro de largo y alcanza $\,$

los 25 kg de peso, y la fuerte musculatura que debe a su hábitat. La pesca intensiva, deportiva y comercial, ha mermado sensiblemente su población en el río Paraná, que fuera antaño su principal reservorio, y los daños ecológicos causados por la represa de Yacyretá han agravado la situación. Hoy su pesca en Argentina está controlada, existiendo veda en la época de reproducción y restricciones al tamaño mínimo de las piezas cobradas.

Se alimenta generalmente de sábalos, bagres, tarariras, palometas, cascarudos, anguilas, morenas y mojarras, peces pequeños que se mueven en cardúmenes. Gracias a su anatomía tiene la posibilidad de ingerir presas de gran tamaño y realizar una ingestión rápida Las

TFM

Alumna: María Carolina Passarello.

diferentes modalidades con el que el pescador cuenta son la mosca, spining, trolling, o con carnadas. Aunque el dorado acostumbra a consumir todo aquello que se le ofrezca, tanto carnadas naturales como artificiales.

La pesca se puede realizar, tanto en lugares muy bajos como en aguas del río Paraná (que llega a tener diez metros de profundidad) y se obtienen los mismos resultados. El río crecido, el agua turbia o clara no dificultan la pesca, ya que este animal se adapta fácilmente. En la pesca deportiva, no existe otro pez que ofrezca una lucha tan dura como el dorado. La lucha entre el pescador y su presa suele durar largos minutos de adrenalina y tensión. La pesca del dorado es considerada como una de las mejores y más famosas a nivel mundial debido a la emoción que genera y a la belleza de la codiciada presa.

Respuesta generada con RAG Básico:

La información proporcionada no menciona específicamente la pesca costera artesanal del dorado. Sin embargo, se describe la pesca costera artesanal en general como aquella que se realiza siempre a vista de costa en aguas de jurisdicción provincial, con embarcaciones que alcanzan como máximo los 18 metros de eslora y que utilizan artes de pesca permitidos. Los artes de pesca se definen como elementos construidos por paños tejidos en forma manual o a máquina con hilos de fibras naturales o sintéticas, con una línea de flotación y otra de peso, capaces de capturar peces generalmente a bordo de una embarcación.

En cuanto al dorado, se menciona que es un pez de agua dulce que habita en las cuencas de los ríos Paraná, Paraguay, Uruguay, Chapare y Mamoré en América del Sur. Es uno de los principales objetos de pesca deportiva en la Argentina y se caracteriza por su fuerza y resistencia a la pesca. La pesca del dorado se puede realizar con diferentes modalidades como la mosca, spinning, trolling o con carnadas, tanto naturales como artificiales.

Por lo tanto, aunque no se especifica cómo se realiza la pesca costera artesanal del dorado, se puede inferir que se utilizarían embarcaciones y artes de pesca permitidos, y que la pesca se llevaría a cabo en aguas de jurisdicción provincial, siempre a vista de costa.

Métricas

ROUGE-1 score: Score(precision=0.5907172995780591, recall=0.3684210526315789, fmeasure=0.45380875202593196) ROUGE-2 score: Score(precision=0.18220338983050846, recall=0.11345646437994723, fmeasure=0.13983739837398373) ROUGE-L score: Score(precision=0.2616033755274262, recall=0.1631578947368421, fmeasure=0.20097244732576985) BERTScore - Precision: 0.696532666683197, Recall: 0.6792471408843994, F1: 0.6877812743186951

Análisis de las Métricas

1. ROUGE-1 Score:

- o **Precision**: 0.591 indica que el 59.1% de las palabras generadas son relevantes en comparación con el texto de referencia.
- o **Recall**: 0.368 muestra que el sistema recupera el 36.8% de las palabras relevantes, lo que sugiere que el sistema es más **preciso** que **exhaustivo**.
- F1-Score: 0.454 refleja un desequilibrio entre precisión y recall, con mayor capacidad para generar palabras relevantes, pero con limitaciones en la recuperación de todas las palabras clave.

2. ROUGE-2 Score:

- o **Precision**: 0.182 indica que el 18.2% de los bigrams generados son correctos en comparación con el texto de referencia.
- **Recall**: 0.113 sugiere que el sistema recupera el 11.3% de los bigrams relevantes.
- F1-Score: 0.140 refleja un rendimiento bajo en la captura de secuencias de palabras significativas, con un enfoque en la precisión pero con una recuperación limitada.

3. ROUGE-L Score:

- o **Precision**: 0.262 sugiere que el 26.2% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.163 indica que el sistema recupera el 16.3% de la secuencia relevante más larga.
- o **F1-Score**: 0.201 refleja un **rendimiento bajo** en la captura de secuencias estructuradas, con **baja recuperación**.

4. BERTScore:

- o **Precision**: 0.697 muestra que el 69.7% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.679 indica que el sistema captura el 67.9% del contenido semántico relevante.
- F1-Score: 0.688 refleja un buen equilibrio entre precisión y recall en términos de correspondencia semántica, con un rendimiento moderado.

Conclusión: Las métricas ROUGE indican que el sistema es más preciso que exhaustivo en la generación de palabras y secuencias relevantes, pero tiene limitaciones en el recall. El rendimiento en secuencias, especialmente en bigrams (ROUGE-2), es bajo, lo que sugiere dificultades en la captura de relaciones más complejas entre palabras. El BERTScore muestra un rendimiento moderado en términos de semántica, capturando una parte importante del significado general, pero con espacio para mejorar tanto en la precisión como en la recuperación de secuencias relevantes.

Respuesta generada con RAG con Haystack:

La pesca costera artesanal del dorado no está específicamente detallada en el documento proporcionado. Sin embargo, se menciona que el dorado es uno de los principales objetos de pesca deportiva en Argentina, junto con las distintas especies de surubí. La pesca del dorado es conocida por su dificultad y emoción, ya que el dorado ofrece una lucha formidable y salta muy alto antes de ser atrapado.

El dorado habita en aguas tropicales y subtropicales de las cuencas de los ríos Paraná, Paraguay, Uruguay, Chapare y Mamoré en América del Sur. Se caracteriza por ser un buen nadador y prefiere aguas de fuertes correntadas. La pesca intensiva, deportiva y comercial ha mermado su población en el río Paraná, y los daños ecológicos causados

TFM

Alumna: María Carolina Passarello.

por la represa de Yacyretá han agravado la situación. Actualmente, la pesca del dorado en Argentina está controlada, con vedas en la época de reproducción y restricciones al tamaño mínimo de las piezas cobradas.

Las modalidades de pesca del dorado incluyen la mosca, spinning, trolling y el uso de carnadas, tanto naturales como artificiales. La pesca se puede realizar tanto en lugares muy bajos como en aguas profundas del río Paraná, y el dorado se adapta fácilmente a diferentes condiciones de agua, ya sea turbia o clara.

La Fiesta Nacional de Pesca del Dorado se lleva a cabo en la localidad de Paso de la Patria, organizada por la Municipalidad de dicha localidad. Esta fiesta incluye exposiciones, concursos de pesca embarcada y de costa, espectáculos folklóricos y actividades recreativas, deportivas y culturales. Se premia al Equipo Mejor Calificado y a la Pieza Mayor.

En resumen, aunque no se detalla específicamente la pesca costera artesanal del dorado, se menciona que es una especie muy valorada en la pesca deportiva y que su captura está regulada para proteger su población.

Métricas:

ROUGE-1 score: Score(precision=0.6886792452830188, recall=0.5763157894736842, fmeasure=0.6275071633237822) ROUGE-2 score: Score(precision=0.4037854889589905, recall=0.33773087071240104, fmeasure=0.36781609195402293) ROUGE-L score: Score(precision=0.46855345911949686, recall=0.39210526315789473, fmeasure=0.4269340974212035) BERTScore - Precision: 0.8076164126396179, Recall: 0.7816240787506104, F1: 0.7944076061248779

Análisis de las Métricas.

1. ROUGE-1 Score:

- o **Precision**: 0.689 indica que el 68.9% de las palabras generadas son relevantes en comparación con el texto de referencia.
- Recall: 0.576 muestra que el sistema recupera el 57.6% de las palabras relevantes, lo que indica que el sistema tiene una alta precisión pero un recall moderado.
- F1-Score: 0.628 refleja un buen equilibrio entre precisión y recall, lo que sugiere que el sistema genera una cantidad significativa de contenido relevante.

2. ROUGE-2 Score:

- **Precision**: 0.404 indica que el 40.4% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 0.338 sugiere que el sistema recupera el 33.8% de los bigrams relevantes.
- F1-Score: 0.368 refleja un rendimiento moderado en la captura de secuencias de dos palabras, con un mayor enfoque en la precisión, pero un recall limitado.

3. ROUGE-L Score:

- o **Precision**: 0.469 indica que el 46.9% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- **Recall**: 0.392 muestra que el sistema recupera el 39.2% de la secuencia relevante más larga.
- o **F1-Score**: 0.427 refleja un **rendimiento moderado** en términos de estructura y secuencias, con una mayor precisión que recall.

4. **BERTScore**:

- o **Precision**: 0.808 muestra que el 80.8% de las palabras generadas son semánticamente relevantes.
- Recall: 0.782 indica que el sistema captura el 78.2% del contenido semántico relevante.
- F1-Score: 0.794 refleja un buen equilibrio entre precisión y recall en términos de correspondencia semántica, lo que sugiere que el sistema capta bien el significado general del texto de referencia.

Conclusión: Las métricas ROUGE indican que el sistema tiene una alta precisión pero un recall moderado, lo que significa que genera contenido relevante pero no captura todo el contenido esperado. El rendimiento en secuencias es moderado, con espacio para mejorar en la recuperación de relaciones entre palabras (ROUGE-2). El BERTScore muestra un rendimiento semántico fuerte, con un buen equilibrio entre precisión y recall, lo que sugiere que el sistema es coherente en términos de significado, pero aún puede mejorar en la captura de secuencias más complejas.

Respuesta generada con RAG con LLamaIndex

La pesca costera artesanal del dorado se realiza utilizando diversas modalidades como la mosca, spinning, trolling o con carnadas. El dorado es conocido por su adaptabilidad, ya que se puede pescar tanto en aguas muy bajas como en profundidades de hasta diez metros en el río Paraná. Este pez es capaz de consumir tanto carnadas naturales como artificiales, y las condiciones del agua, como si está turbia o clara, no afectan significativamente la pesca debido a su capacidad de adaptación. La pesca del dorado es famosa por la emoción y la lucha que ofrece, siendo una de las más apreciadas a nivel mundial.

Métricas

```
ROUGE-1 score: Score(precision=0.8037383177570093, recall=0.22631578947368422, fmeasure=0.3531827515400411) ROUGE-2 score: Score(precision=0.4056603773584906, recall=0.11345646437994723, fmeasure=0.17731958762886596) ROUGE-L score: Score(precision=0.4485981308411215, recall=0.12631578947368421, fmeasure=0.1971252566735113) BERTScore - Precision: 0.7826068997383118, Recall: 0.6870729327201843, F1: 0.7317349314689636
```

Análisis de las Métricas

1. ROUGE-1 Score:

- o **Precision**: 0.804 indica que el 80.4% de las palabras generadas son relevantes en comparación con el texto de referencia.
- Recall: 0.226 sugiere que el sistema recupera solo el 22.6% de las palabras relevantes, lo que indica un recall muy bajo.
- F1-Score: 0.353 refleja un desequilibrio considerable entre precisión y recall, lo que sugiere que el sistema genera una cantidad significativa de contenido relevante pero no es exhaustivo.

2. ROUGE-2 Score:

- o **Precision**: 0.406 indica que el 40.6% de los bigrams generados coinciden con los del texto de referencia.
- **Recall**: 0.113 muestra que el sistema recupera solo el 11.3% de los bigrams relevantes.
- F1-Score: 0.177 refleja un rendimiento bajo en la captura de secuencias significativas, con un enfoque en la precisión pero con una baja capacidad de recuperación.

3. ROUGE-L Score:

- o **Precision**: 0.449 indica que el 44.9% de las coincidencias generadas pertenecen a la secuencia más larga de coincidencias.
- o **Recall**: 0.126 sugiere que el sistema recupera solo el 12.6% de la secuencia relevante más larga.
- F1-Score: 0.197 refleja un rendimiento bajo en términos de estructura de secuencias, nuevamente destacando la alta precisión pero el bajo recall.

4. BERTScore:

- o **Precision**: 0.783 muestra que el 78.3% de las palabras generadas son semánticamente relevantes.
- **Recall**: 0.687 indica que el sistema captura el 68.7% del contenido semántico relevante.
- F1-Score: 0.732 refleja un buen equilibrio entre precisión y recall en términos de correspondencia semántica, aunque con margen de mejora en la capacidad de recuperación.

Conclusión: Las métricas ROUGE indican que el sistema tiene una alta precisión pero un recall muy bajo, lo que significa que genera contenido relevante pero no captura la mayoría del contenido esperado. El rendimiento en secuencias y estructura (ROUGE-2 y ROUGE-L) es especialmente bajo, lo que sugiere dificultades en la captura de relaciones entre palabras y en generar respuestas exhaustivas. El BERTScore muestra un buen rendimiento semántico, con un buen equilibrio entre precisión y recall, aunque también refleja la necesidad de mejorar la exhaustividad en la generación de contenido.